Collège Sciences et Technologies
UF Mathématiques et Interactions

Optimisation multicritère de l'alimentation porcine : vers un équilibre économique et environnemental

Cyprien Quettier

L'IFIP - Institut du porc

Master Recherche opérationnelle et aide à la décision

2024–2025

Engagement de non plagiat

Je, [Cyprien Quettier], m'engage fermement à éviter tout acte de plagiat dans ce rapport.
En signant cet engagement :

- Je m'engage à citer correctement toutes les sources utilisées dans mes travaux, en suivant les conventions de citation appropriées.
- Je m'engage à produire un rapport original, évitant tout recours direct ou indirect au travail d'autrui sans attribution adéquate.
- Je m'engage à respecter les droits d'auteur et la propriété intellectuelle, en obtenant les autorisations nécessaires pour utiliser et citer des œuvres protégées par le droit d'auteur.

Je comprends que tout acte de plagiat peut entraîner des conséquences disciplinaires.

Le [09/04/2025]

Signature
[Cyprien Quettier]

Engagement à l'égard de l'Intelligence Artificielle

Je, [Cyprien Quettier], m'engage à ne pas utiliser d'Intelligence Artificielle générative de texte dans le cadre de la rédaction de ce rapport.

Je comprends que toute violation de cet engagement peut entraîner des conséquences disciplinaires. En signant ci-dessous, je m'engage à respecter ces consignes.

Le [09/04/2025]

Signature
[Cyprien Quettier]

Résumé

Ce travail s'inscrit dans une démarche d'aide à la décision dans le secteur de l'alimentation porcine. Son objectif principal est le développement d'un calculateur multicritère, conçu à la fois pour outiller les fabricants d'aliments et à la fois pour appuyer de futurs travaux scientifiques. Cet outil vise à identifier des formulations d'aliments équilibrées, conciliant impératifs économiques et environnementaux.

Pour cela, les modèles et données du projet EcoAlim ont été repris comme base de référence. Les méthodes de résolution utilisées dans ce projet (pondération, méthode -contrainte) ont été réimplantées, étendues et systématiquement comparées. Plusieurs techniques de normalisation ont été évaluées afin de garantir la comparabilité des critères.

L'évaluation des performances repose sur l'utilisation de métriques multiobjectifs (indice DCI, énergie de Riesz, indice PCI, dispersion). Deux jeux de données réels, correspondant aux phases "growing" et "finishing", ont été utilisés pour valider les approches.

Les expérimentations ont permis d'analyser l'influence des choix méthodologiques sur la qualité des fronts de Pareto générés. Une analyse de sensibilité aux pondérations a également été menée pour mieux comprendre la structure du problème.

L'ensemble de ces analyses a permis de justifier rigoureusement le choix final de la méthode et de la normalisation implémentées dans le calculateur. Ce dernier constitue un outil reproductible, flexible et fondé sur une méthodologie éprouvée.

Ce travail montre que l'optimisation multicritère répond efficacement aux enjeux complexes de durabilité dans la filière porcine.

Mots clés : Optimisation multicritère, Formulation d'aliments, Filière porcine, Durabilité environnementale, Calculateur d'aide à la décision

Abstract

This work contributes to decision support in the field of pig feed formulation. Its primary objective is the development of a multi-objective calculator, designed both to assist feed manufacturers and to support future scientific research. The tool aims to identify balanced feed formulations that reconcile economic and environmental constraints.

To achieve this, the models and datasets from the EcoAlim project were used as a reference. The resolution methods applied in this project (weighted sum, -constraint method) were re-implemented, extended, and systematically compared. Several normalization techniques were assessed to ensure the comparability of objectives.

Performance was evaluated using multi-objective metrics such as the Directional Coverage Index (DCI), Riesz energy, Performance Comparison Indicator (PCI), and dispersion measures. Two real-world datasets, corresponding to the "growing" and "finishing" pig production phases, were used for validation.

The experiments allowed for an analysis of the methodological choices' influence on the quality of the generated Pareto fronts. A sensitivity analysis on weight distributions was also conducted to better understand the problem structure.

These analyses led to a rigorous justification of the final method and normalization selected for implementation in the calculator. The resulting tool is reproducible, flexible, and grounded in a validated methodology.

This study demonstrates that multi-objective optimization offers a robust framework to address the complex challenges of sustainability in the pig farming sector.

Keywords: Multi-objective optimization, Feed formulation, Pig production, Environmental sustainability, Decision-support tool

Table des matières

1 Introduction **6**

2 Optimisation Multiobjectif **7**
2.1 Notions fondamentales en optimisation multicritère . . . 7
2.1.1 Définitions et cadre de la programmation linéaire multicritère . . . 7
2.1.2 Notions de dominance . . . 7
2.1.3 Distinction entre solutions supportées et non supportées . . . 10
2.1.4 Normalisation des critères . . . 10
2.2 Approches de résolution . . . 11
2.2.1 Approche non-scalaire : méthode lexicographique . . . 11
2.2.2 Approche scalaire . . . 12
2.2.3 Méthode heuristique . . . 15

3 Projet EcoAlim **19**
3.1 Historique . . . 19
3.2 Présentation du projet EcoAlim . . . 19
3.3 Formalisation du problème d'optimisation . . . 20
3.4 Modélisation . . . 21
3.5 Bilan des contributions au projet EcoAlim . . . 22
3.5.1 Florence Garcia-Launay et al. (2018) : Multiobjective formulation is an effective-method to reduce environmental impacts of livestock feeds . . . 22
3.5.2 Cécile Crolard (2018) : Formulation multiobjectif d'aliments pour truites et porcs en croissance . . . 23
3.6 Conclusion . . . 25

4 Contributions **26**
4.1 Introduction . . . 26
4.2 Métriques d'évaluation multiobjectif . . . 27
4.2.1 Fondements généraux . . . 27
4.2.2 Indice DCI (Directional Coverage Index) . . . 27
4.2.3 Énergie de Riesz . . . 28
4.2.4 Dispersion moyenne et extension maximale . . . 29
4.2.5 Indice PCI (Performance Comparison Indicator) . . . 29
4.2.6 Paramètres de calcul et adaptations expérimentales . . . 30
4.3 Analyse comparative des normalisations de génération des fronts . . . 30
4.3.1 Résultats sur la phase Growing . . . 30
4.3.2 Résultats sur la phase Finishing . . . 30
4.4 Analyse comparative des méthodes de génération des fronts de Pareto . . . 31
4.4.1 Résultats sur la phase Growing . . . 31
4.4.2 Résultats sur la phase Finishing . . . 33
4.5 Synthèse finale sur la méthode et la normalisation recommandées . . . 34

5 Approfondissement de l'analyse multi-objectif **35**
5.1 Analyse quantitative de la variabilité interne du front 35
5.2 Analyse multidimensionnelle par représentations en coordonnées parallèles 35
5.3 Analyse des solutions extrêmes 37
5.4 Corrélations et interactions entre objectifs 38
5.5 Extension de l'algorithme Greedy Reduction aux contraintes économiques 39

6 Analyse de la sensibilité aux pondérations dans la génération des fronts **41**
6.1 Impact du nombre d'itérations sur la taille du front 41
6.2 Répartition des pondérations contributives 43

7 Conclusion **47**

8 Annexe **48**

1 Introduction

En ce début d'année 2025 les tensions géopolitiques sont croissantes et le Président de la République, Emmanuel Macron, a appelé à renforcer la souveraineté alimentaire de la France et de l'Europe. C'est en réponse à cet appel que La Coopération Agricole, 2025 affirme de nouveau son engagement en faveur de la sécurité alimentaire. Ce communiqué de presse, daté du 6 mars 2025, expose les principales mesures préconisées par les coopératives agricoles françaises : la sécurisation des financements agricoles, la protection des filières face aux barrières commerciales, la résilience climatique et sanitaire, la relocalisation des productions stratégiques, et l'attractivité des métiers agricoles.

La sécurité alimentaire se définit comme l'accès pour tous et par tous à une alimentation suffisante, saine et nutritive. Mais cette sécurité repose aussi, et de plus en plus, sur les choix des consommateurs. Mieux informés, ceux-ci deviennent plus critiques et exigeants sur leur consommation de viande. Pour certains, le bien-être animal prime ; pour d'autres, c'est l'impact environnemental qui pèse dans la balance ; d'autres encore privilégient un prix compétitif. En France, d'après Statista, 2023 pour 58% des Français, le premier critère d'achat pour la viande reste le prix.

L'industrie porcine reste un pilier de la consommation de viande en France avec près de 2,2 millions de tonnes équivalent-carcasse consommées en 2022 (FranceAgriMer, 2023) devant la viande bovine et de volaille (Agreste, 2024). Pour autant, une baisse de consommation de 5% en 2023 est relevée du fait de l'évolution des habitudes alimentaire. Les acteurs de la filière porcine doivent adapter leurs modèles de production, repenser leurs pratiques en matière de bien-être animal, d'alimentation, ou encore de traçabilité. De plus, la filière porcine française repose sur une chaîne d'acteurs interdépendants mais aux intérêts parfois divergents : les éleveurs, les groupements de producteurs, les abattoirs-transformateurs et les distributeurs. Cette interdépendance, essentielle au bon fonctionnement de la filière, s'accompagne de tensions structurelles, économiques et stratégiques. C'est dans ce contexte que l'IFIP – Institut du Porc joue un rôle central. En tant qu'institut technique et scientifique de référence pour la filière, l'IFIP apporte une expertise impartiale et fondée sur la recherche appliquée. Il agit comme un tiers de confiance capable de produire des données objectives, d'analyser les évolutions techniques, économiques et environnementales, et de proposer des solutions concrètes pour améliorer la compétitivité et la durabilité de l'ensemble de la filière.

Par ailleurs, en 2020 la part des émissions de gaz à effet de serre (GES) de l'agriculture s'élève à 20% (80,9 MteqCO2) des émissions françaises (Ministère de l'Agriculture et de la Souveraineté Alimentaire, 2022). Au sein de cette part d'émissions, l'alimentation animale représente plus de 35% des émissions du domaine porcin (INRAE, 2021). Cette contribution est évaluée par une méthode dite d'analyse de cycle de vie (ACV). Une évaluation au portail de la ferme comprend une évaluation de la production des aliments destinés à l'élevage, la production des autres intrants de l'élevage (carburant, matériel...), l'atelier animal (dont les émissions de méthane entérique) et la gestion des effluents (et les émissions gazeuses associées).

Dans ce contexte où les enjeux sont multiples, il s'agit de concilier des objectifs parfois contradictoires : réduire l'empreinte environnementale de l'alimentation porcine tout en maintenant la souveraineté alimentaire, notamment à travers un contrôle des coûts. Le projet EcoAlim, porté par l'IFIP, s'inscrit dans cette logique multiobjectif en proposant des formulations d'aliments pour porcs à la fois durables sur le plan environnemental et économiquement accessibles.

Dans une premiere partie les fondements théoriques de l'optimisation multi-objectif seront introduits. En second lieu, l'historique du projet EcoAlim sera abordé. Le chapitre 4 expose mes propres contributions, ainsi que leur évaluation via des métriques quantitatives. Enfin, les chapitres 5 et 6 approfondissent l'analyse des résultats avant de conclure.

2 Optimisation Multiobjectif

L'objectif de ce chapitre est de fournir un cadre théorique et pratique avec une présentation des outils qui seront appliqués au cas du projet EcoAlim.

2.1 Notions fondamentales en optimisation multicritère

Dans cette section, nous allons définir des notions fondamentales dans la programmation linéaire multicritère.

2.1.1 Définitions et cadre de la programmation linéaire multicritère

La programmation linéaire multicritère généralise la programmation linéaire classique. En effet, en remplaçant une unique fonction objectif par un vecteur d'objectifs, cette approche permet de visualiser les compromis disponibles entre les différents objectifs (Ehrgott, 2005).

Définition 1 (Problème multiobjectif)**.** *Un problème de modélisation multiobjectif consiste à optimiser simultanément plusieurs fonctions objectifs.*

Soit $\mathcal{J} = \{x_1, x_2, ..., x_n\}$ l'ensemble des variables de décision, et $\mathcal{O} = \{f_1, f_2, \ldots, f_m\}$ l'ensemble des fonctions objectifs, avec : $f_i : \mathbb{R}^n \to \mathbb{R}, \quad \forall i \in \{1, \ldots, m\}$ où $\mathcal{X} \subseteq \mathbb{R}^n$ désigne l'ensemble des solutions admissibles, c'est-à-dire l'ensemble des vecteurs $x = (x_j)_{j \in \mathcal{J}}$ qui satisfont les contraintes du problème.

Le problème multiobjectif s'écrit alors :

$$\min_{x \in \mathcal{X}} (f_1(x), f_2(x), \ldots, f_m(x))$$

Définition 2 (Espace de décision et espace objectif)**.** *Dans le cadre de la modélisation des problèmes d'optimisation multicritère, il est important de distinguer les structures qui les définissent : l'espace de décision et l'espace objectif.*

- *L'espace de décision (ou espace des variables), noté $\mathcal{X} \subseteq \mathbb{R}^n$, désigne l'ensemble des solutions admissible.*
- *L'espace objectif $\mathcal{Y}$ est l'image de l'ensemble des solutions réalisables $\mathcal{X}$ par le vecteur de fonctions objectifs $f : \mathbb{R}^n \to \mathbb{R}^m$. Autrement dit, $\mathcal{Y} = \{(f_1(x), f_2(x), \ldots, f_m(x)) \in \mathbb{R}^m \mid x \in \mathcal{X}\}$.*

La transformation des solutions réalisables $\mathcal{X}$ vers les valeurs des objectifs $\mathcal{Y}$ est illustrée à la Figure 2.1.

2.1.2 Notions de dominance

En optimisation multi-objectif, l'optimalité de Pareto est utilisée pour analyser des compromis entre plusieurs objectifs contradictoires. En effet, pour un problème multiobjectif il n'y a pas d'ordre total entre les solutions (i.e., un optimum global) mais un ordre partiel (Jozefowiez, 2013b).

Exemple 2.1.1. *Considérons un problème à deux objectifs contradictoires :*

- *Minimiser le **coût** (en euros),*
- *Minimiser l'**impact environnemental** (exprimé en score CO_2).*

Cinq solutions candidates sont évaluées comme suit :

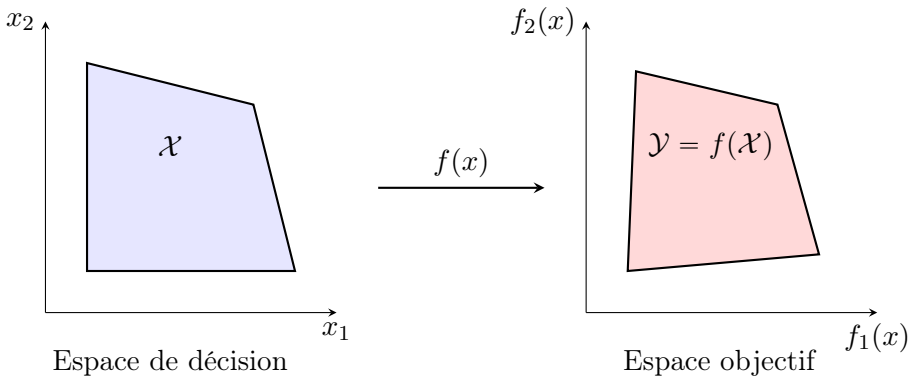

FIGURE 2.1 – Illustration de l'espace de décision $\mathcal{X}$ et l'espace objectif $\mathcal{Y}$ via l'application $f(x)$.

Solution	***Coût (€)***	***Impact (CO_2)***
A	*100*	*50*
B	*80*	*60*
C	*120*	*40*
D	*90*	*70*
E	*120*	*55*

Un problème multiobjectif s'écrit généralement sous la forme suivante :

$$\begin{cases} \min & (f_1(x), f_2(x), \ldots, f_m(x)) \\ \text{s.c. :} & x \in \mathcal{X} \end{cases} \tag{2.1}$$

où $\mathcal{X}$ est l'ensemble des solutions admissibles, et les fonctions $f_1, \ldots, f_m$ sont les objectifs à minimiser. En reprenant notre exemple 2.1.1, posons $f_{\text{Coût}}$ et f_{Impact} avec $\mathcal{X} = \{A, B, C, D, E\}$.

Définition 3 (Pareto-optimalité au sens strict)**.** *Une solution $x^* \in \mathcal{X}$ est dite Pareto-optimale ou efficiente pour le problème* (2.1) *s'il n'existe aucune autre solution $x \in \mathcal{X}$ telle que :*

$$\forall i \in \{1, \ldots, m\}, \quad f_i(x) \leqslant f_i(x^*) \quad \textit{et} \quad \exists j \in \{1, \ldots, m\}, \quad f_j(x) < f_j(x^*)$$

Autrement dit, aucune solution ne permet d'améliorer un objectif sans en dégrader au moins un autre.

Dans l'exemple 2.1.1, les solutions correspondant aux points B et C ne sont dominées par aucune autre, et donc *Pareto-optimales*. En revanche, les solutions correspondant aux points A, D et E sont *dominées* : il existe d'autres solutions qui leur sont strictement préférables sur tous les objectifs.

Définition 4 (Faible Pareto-optimalité)**.** *Une solution $x^* \in \mathcal{X}$ est dite faiblement Pareto-optimale pour le problème* (2.1) *s'il n'existe aucune solution $x \in \mathcal{X}$ telle que :*

$$\forall i \in \{1, \ldots, m\}, \quad f_i(x) < f_i(x^*)$$

Autrement dit, aucune solution ne permet d'améliorer simultanément tous les objectifs de manière stricte.

Théorème 1. *Toute solution Pareto-optimale est faiblement Pareto-optimale. En revanche, l'inverse n'est pas toujours vrai : il peut exister des solutions faiblement Pareto-optimales qui ne sont pas Pareto-optimales.*

Définition 5 (Front de Pareto)**.** *Le front de Pareto est l'ensemble des images, dans l'espace des objectifs, des solutions Pareto-optimales :*

$$\mathcal{F}^* = \{f(x) \in \mathbb{R}^m \mid x \in \mathcal{X},\ x \textit{ est Pareto-optimale}\}$$

Cet ensemble contient tous les points non dominés dans l'espace objectif : aucun de ces points ne peut être amélioré simultanément sur tous les objectifs.

Pour illustrer ce concept, supposons que nous cherchons à minimiser $f_1(x)$ et $f_2(x)$:

$$\begin{cases} \min & (f_1(x), f_2(x)) \\ \text{s.c. :} & x \in \mathcal{X} \end{cases}$$

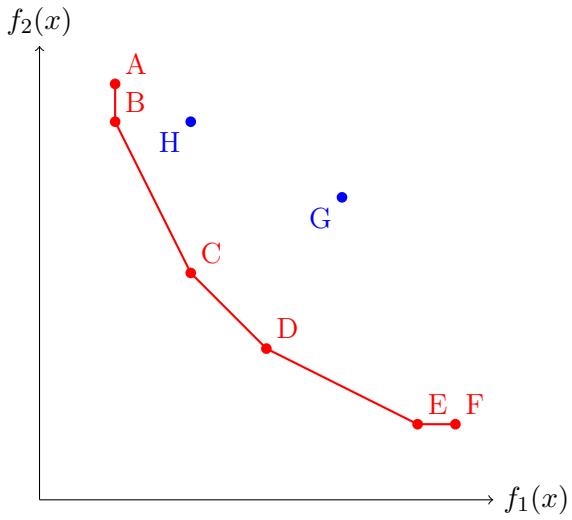

Les points B, C, D et E représentent des images dans l'espace objectif de solutions Pareto-optimales. Ils constituent l'ensemble des points non dominés.

Les points G et H, quant à eux, sont dominés et n'appartiennent pas au front de Pareto.

Les points A et F sont faiblement Pareto-optimaux : bien qu'ils soient dominés (respectivement par B et E), aucune solution n'est strictement meilleure qu'eux sur l'ensemble des objectifs.

2.1.3 Distinction entre solutions supportées et non supportées

Théorème 2. *Au sein d'un espace objectif de dimension m, si les fonctions $f_o(x), \forall o \in \mathcal{O}$ sont linéaires et que le domaine $\mathcal{X}$ est convexe alors l'image $\mathcal{Y} = f(\mathcal{X})$ est également convexe (Miettinen, 1999). Cependant, si le domaine $\mathcal{X}$ est non convexe ou qu'au moins une fonction $f_o(x), \forall o \in \mathcal{O}$ est non convexe alors l'ensemble des points non dominés est concave.*

Définition 6. *[Solutions non supportées] Les solutions non supportées sont des solutions Pareto-optimales qui ne se trouvent pas sur les segments de la frontière convexe formée par le front de Pareto.*

Elles apparaissent généralement dans des fronts de Pareto concaves ou comportant des sections non linéaires.

Pour illustrer ce concept, considérons les exemples suivants :

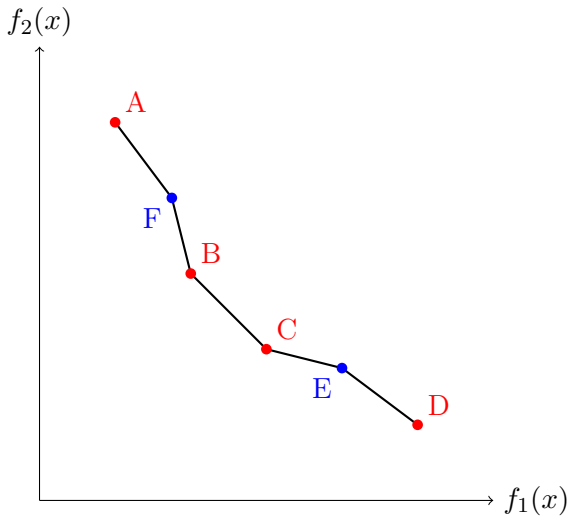

Dans cette figure, les points A, B, C, D, E, F correspondent aux images dans l'espace objectif de solutions Pareto-optimales, formant un front de Pareto concave. Les points E et F (en bleus) représentent des *points non supportés* : ce sont des images de solutions qui ne se trouvent pas sur l'enveloppe convexe du front de Pareto, bien qu'elles puissent être non dominées. Les points A, B, C et D (en bleus) représentent des *points supportés* : ce sont des images de solutions qui se trouvent sur l'enveloppe convexe du front de Pareto.

2.1.4 Normalisation des critères

Dans le cadre de la programmation linéaire multicritère, les objectifs sont généralement exprimés dans des unités différentes (par exemple, coût en euros, impact environnemental en kg CO_2-eq). Afin de garantir leur comparabilité, il est nécessaire de procéder à une *normalisation* des critères.

On considère une fonction objectif multi-critère exprimée sous la forme vectorielle :

$$\min_{x \in \mathcal{X}} (f_1(x), f_2(x), \ldots, f_m(x)) \Longleftrightarrow (C_1 \cdot x, C_2 \cdot x, \ldots, C_{\mathcal{O}} \cdot x) \tag{2.2}$$

où chaque vecteur $C_o = (c_{(1,o)}, c_{(2,o)}, \ldots, c_{(n,o)}) \in \mathbb{R}^n$ regroupe les coefficients de l'objectif f_o, pour $o \in \mathcal{O}$.

La normalisation consiste à transformer chaque vecteur de coefficients C_o en un vecteur C'_o, selon une règle définie par le décideur ou le contexte du problème. Cette transformation est notée :

$$C'_o = \mathcal{N}(C_o)$$

où $\mathcal{N}$ désigne une opération de normalisation appliquée à tous les coefficients d'un objectif donné.

La fonction objectif devient alors :

$$\min_{x \in \mathcal{X}} \left(\tilde{f}_1(x), \tilde{f}_2(x), \ldots, \tilde{f}_m(x)\right) \Longleftrightarrow \left(C'_1 \cdot x, C'_2 \cdot x, \ldots, C'_m \cdot x\right) \tag{2.3}$$

Cette étape de normalisation permet d'exprimer les différents objectifs sur une base comparable, sans altérer la structure du problème de décision sous-jacent.

2.2 Approches de résolution

Cette section présente un aperçu des principales méthodes de résolution. La résolution d'un problème multiobjectif consiste à définir un ensemble de solutions non-dominées (définition 3). Dans cette section, plusieurs méthodes de résolutions seront abordées, qu'elles soient exactes ou approchées.

2.2.1 Approche non-scalaire : méthode lexicographique

Les méthodes non-scalaires utilisent des mécanismes spécifiques pour chaque objectif.

S'il existe une hiérarchie entre les objectifs, on peut utiliser la méthode lexicographique pour résoudre notre problème multiobjectif (Jozefowiez, 2013b). Chaque étape de l'optimisation prend en compte les objectifs précédemment optimisés en ajoutant des contraintes pour conserver leurs valeurs optimales. La méthode lexicographique peut s'exprimer de la manière suivante :

Supposons que l'on ait un ensemble $\mathcal{O}$ de fonctions objectives, classées de telle sorte que si $o < o'$ alors f_o est prioritaire sur $f_{o'}$. On résout d'abord le problème :

$$\begin{cases} \min & f_1(x) \\ \text{s.c. :} & x \in \mathcal{X} \end{cases}$$

On obtient alors x_1, la meilleure solution trouvée pour f_1, associée à la valeur $f_1^* = f_1(x_1)$. f_1^* devient alors une contrainte du problème associé à f_2 :

$$\begin{cases} \min & f_2(x) \\ \text{s.c. :} & x \in \mathcal{X} \\ & f_1(x) = f_1^* \end{cases}$$

Pour la o-ième itération, nous avons déjà optimisé les $o-1$ premiers objectifs, obtenant ainsi les solutions optimales $x_1, x_2, \ldots, x_{o-1}$ et les valeurs optimales correspondantes $f_1^*, f_2^*, \ldots, f_{o-1}^*$. Nous formulons alors le problème pour le o-ième objectif en ajoutant les contraintes que les $o-1$ premiers objectifs restent à leurs valeurs optimales :

$$\begin{cases} \min & f_o(x) \\ \text{s.c. :} & x \in \mathcal{X} \\ & f_1(x) = f_1^* \\ & f_2(x) = f_2^* \\ & \vdots \\ & f_{o-1}(x) = f_{o-1}^* \end{cases}$$

Cette méthode heuristique permet d'obtenir la meilleure solution x_o pour f_o qui respecte les valeurs optimales des objectifs précédents.

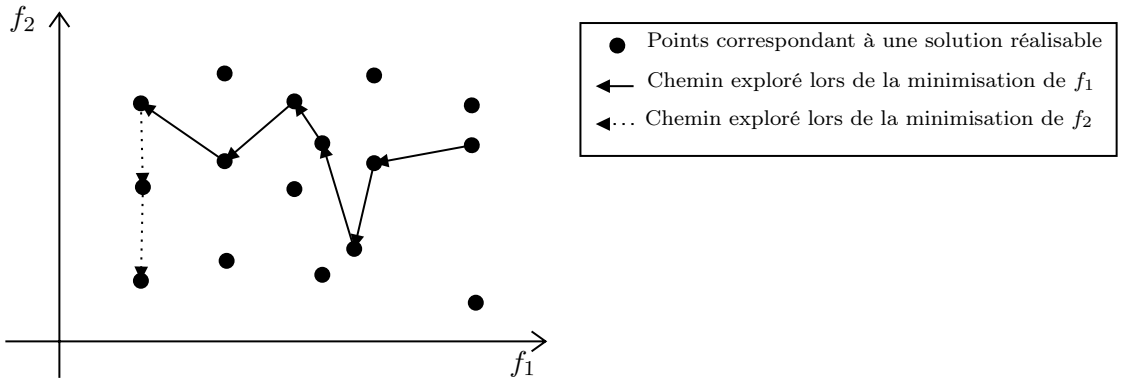

FIGURE 2.2 – Exemple de résolution lexicographique dans l'espace objectif

2.2.2 Approche scalaire

L'approche dite scalaire transforme un problème multiobjectif en un ensemble de problème mono-objectif, domaine dans lequel nous disposons de nombreuses méthodes éprouvées et bien maîtrisées (Jozefowiez, 2013b). Deux méthodes seront présentées : la pondération (Das et al., 1997) et l'ϵ-contrainte (Jozefowiez, 2013b).

La pondération

La pondération est une méthode couramment utilisée dans la résolution des problèmes multiobjectif. Cette technique consiste à itérer sur un problème mono-objectif en attribuant un poids à chaque objectif pour les combiner en une seule fonction objectif. Les poids reflètent l'importance relative des différents objectifs.

En considérant un problème multiobjectifs 2.2 et un vecteur de pondération $w = \{w_1, w_2, ..., w_n\}$, le problème considéré est le suivant :

$$P_w = \begin{cases} \min \sum_{o=1}^{m} w_o f_o(x) \\ \text{s.c. :} \quad x \in \mathcal{X} \end{cases}$$

où $w_o \geqslant 0$ est le poids attribué à l'objectif $f_o(x)$ et $\sum_{o \in \mathcal{O}} w_o = 1$.

A chaque résolution du problème P_w un nouveau vecteur w de pondération est passé en entrée. Ainsi, chaque solution optimale x_w^* est Pareto-optimale (définition 5). Cependant, si le front de Pareto n'est pas convexe, alors cette méthode est incapable de trouver les solutions non-supportées (définition 6). En effet, ces solutions situées dans la zone concave du front (Das et al., 1997) ne sont pas des combinaisons linéaires des autres points, c'est pourquoi la méthode ne trouvera pas d'hyperplan passant par ces points. Elle permet néanmoins d'atteindre les solutions supportées — y compris les solutions faiblement supportées situées sur des segments du front.

Proposition 1. *Si tous les poids du vecteur de pondération $w = (w_1, \ldots, w_m)$ sont strictement positifs, alors toute solution optimale x_w^* du problème P_w est une solution supportée et Pareto-optimale du problème multiobjectif* (2.1).

Proposition 2. *Si certains poids du vecteur w sont nuls, alors la solution optimale x_w^* du problème P_w n'est pas nécessairement Pareto-optimale pour l'ensemble complet des objectifs. Elle est uniquement optimale pour le sous-ensemble des objectifs associés à un poids strictement positif, et peut donc être dominée lorsqu'on considère les objectifs ignorés.*

Voici une figure pour illustrer les limites de la méthode de pondération (figure 2.3), les hyperplans sont dessinés en lignes pointillées, et les solutions bleues sont dites non-supportées (E, F). On constate que la méthode de pondération ne permet pas d'atteindre les solutions non-supportées (définition 6).

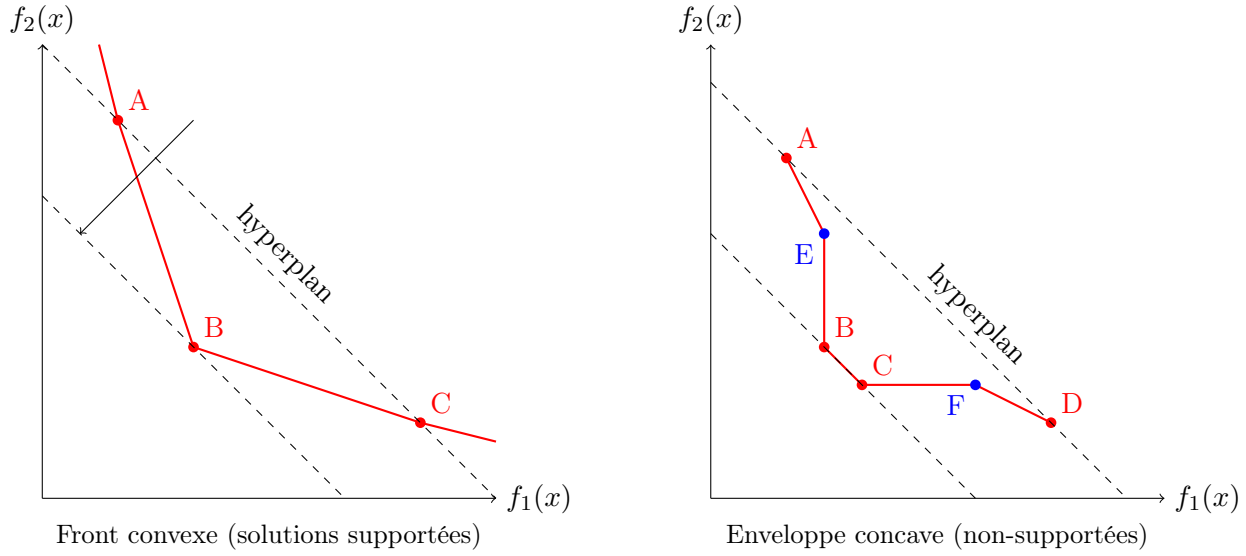

FIGURE 2.3 – Comparaison de la méthode de pondération entre un front de Pareto convexe à gauche et concave à droite admettant des solutions non-supportées

L'epsilon-contrainte

Cette méthode consiste à choisir une seule fonction objectif f_o à optimiser tandis que les autres fonctions $f_{o'}$ sont bornées à l'aide de contraintes (d'où ϵ contrainte). Le problème multiobjectif 2.2 s'écrit donc :

$$P_\epsilon = \begin{cases} \min \quad f_o(x) \\ \text{s.c. :} \\ \quad x \in \mathcal{X}, \\ \quad f_{o'}(x) \leqslant \epsilon_{o'}, \quad \forall o' \in \mathcal{O} \backslash \{o\} \end{cases}$$

Le front de Pareto est construit en faisant varier le vecteur de contraintes ϵ. Contrairement à la méthode de pondération, cette méthode trouve des solutions non-supportées (définition 6), issues de la zone concave du front de Pareto.

Proposition 3. *Toute solution optimale d'un problème ϵ-contrainte P_ϵ est une solution Pareto-optimale (au sens strict) du problème multiobjectif. En particulier, la méthode ne permet pas d'obtenir de solutions qui sont uniquement faiblement efficaces d'après Ehrgott, 2005.*

Voici un exemple pour illustrer ce concept à l'aide du d'optimisation bi-objectif suivant :

$$\min_{x \in \mathcal{X}} \quad (f_1(x), f_2(x))$$

A l'aide de la méthode epsilon-contrainte, on définit le problème P_ϵ :

$$P_\epsilon = \begin{cases} \min \quad f_2(x) \\ \text{s.c. :} \\ \quad x \in \mathcal{X}, \\ \quad f_1(x) \leqslant \epsilon \end{cases}$$

On cherche à optimiser l'objectif f_2 en contraignant l'objectif f_1 à l'aide de ϵ. En considérant 2 itérations, avec ϵ_1 et ϵ_2, voici la résolution graphique dans l'espace des objectifs (définition 2) :

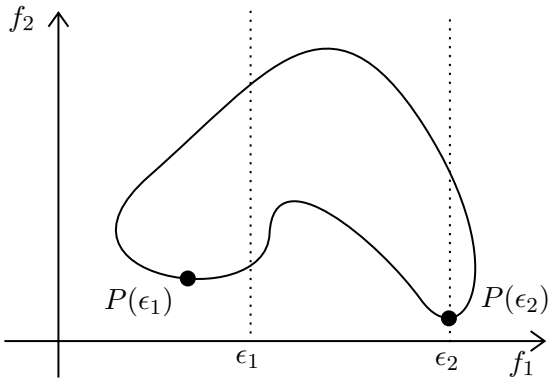

FIGURE 2.4 – Solutions optimales pour deux valeurs de ϵ

2.2.3 Méthode heuristique

Pour résoudre les problèmes multiobjectif (définition 1), il existe plusieurs méthodes heuristiques (Blot et al., 2018). Parmi ces méthodes, on trouve :

— SPEA2 : Strength Pareto Evolutionary Algorithm 2 (Zitzler, Laumanns et al., 2001)
— MOEA/D : Multi-Objective Evolutionary Algorithm based on Decomposition (Zhang et al., 2007)
— MOPSO : Multi-Objective Particle Swarm Optimization (Coello Coello et al., 2002)
— PAES : Pareto Archived Evolution Strategy (Knowles et al., 1999)
— IBEA : Indicator-Based Evolutionary Algorithm (Zitzler et Künzli, 2004a)

Ces heuristiques évaluent les solutions et leur attribuent un score basé sur des critères spécifiques.

Algorithme NSGA-II

Deb et al., 2002 ont introduit l'algorithme NSGA-II (Non-dominated Sorting Genetic Algorithm II), un algorithme d'optimisation évolutif principalement utilisé pour les problèmes d'optimisation multiobjectif. NSGA-II évalue les solutions selon deux critères : le rang de Pareto $R(p)$ et une distance de foule $d(p)$, permettant ainsi d'assurer une diversité et une convergence efficaces des solutions.

1. Initialisation de la population : l'algorithme génère une population initiale aléatoire $\mathcal{P}$.
2. Evaluation des solutions : chaque individu \ solutions $p \in \mathcal{P}$ est évalué par les M fonctions objectifs
3. Tri des solutions par leurs degrés de dominance : attribution d'un rang de Pareto :
   (a) $R(p) = 1$: pour les solutions issues du front de Pareto (ie celles qui ne sont dominées par aucune autre)
   (b) $R(p) = 2$: si elle est dominée seulement par les solutions du rang de Pareto 1 et par aucune autre solution de la population.
   (c) $R(p) = k$: si elle est dominée par au moins une solution de chaque des $k-1$ fronts précédents, mais par aucune solution du rang k ou supérieure
4. Calcul de la distance de foule d (Crowding Distance) : pour p l'évaluation d'une solution issue du front de Pareto dans $\mathbb{R}^M$,
   (a) si $f_o(p) = f_o^{min}$ ou $f_o(p) = f_o^{max}$, la solution est située aux extrémités, alors $d(p) = \infty$
   (b) sinon $d(p) = \sum_{o \in \mathcal{O}} \frac{f_o(p+1) - f_o(p-1)}{f_o^{max} - f_o^{min}}$

   où f_m^{min} est la valeur minimale de la fonction objectif f_m et f_m^{max} est la valeur maximale de la fonction objectif f_m sur le front de Pareto. Ce calcul estime la densité des solutions autour d'une solution donnée. L'algorithme NSGA-II favorise les solutions qui sont dans des régions moins peuplées de l'espace objectif (définition 2).
5. Sélection, croisement et mutation : pour générer une nouvelle population à partir de la population actuelle :
   (a) Sélection au hasard de deux individus p et p' :
      i. Si $R(p) \neq R(p')$ l'algorithme choisit la solution avec le rang de Pareto inférieur (tournois binaire)
      ii. Sinon l'algorithme choisit p tel que $d(p) > d(p')$ (élitisme)

      La sélection favorise les solutions avec de meilleurs rangs de Pareto et des distances de foule plus élevées.
   (b) Croisement des individus sélectionnés (parent) pour créer deux solutions dites enfants :
      i. choisir une des méthodes de croissement de mainière aléatoire. Au sein du vecteur, y choisir une séquence consécutif pour obtenir un chromosome et les échanger :
         A. en leurs commencement (One-Point Crossover)
         B. en leurs milieu (Two-Point Crossover)
         C. ou de manières aléatoires (Uniform Crossover).

         Le croisement génère une population enfant E.

(c) Parmi la population E, choisir e pour introduire de la variabilité génétique, aléatoirement choisir une des 3 mutations suivantes :

   i. une probabilité définie d'échanger les 0 et les 1 (Bit Flip)

   ii. Sélection d'un élément du vecteur, un gène et définition de α :

      A. α : issue d'un Gaussienne (Perturbation Gaussienne)

      B. α choisi dans un domaine

6. Formation d'une nouvelle population : Les enfants générés par les opérateurs de croisement et de mutation sont regroupés avec les parents pour former une population intermédiaire. Ensuite, un nouveau tri par dominance non dominée est effectué pour former la prochaine génération de la population, en conservant un nombre fixe d'individus.

7. Boucle itérative : Les étapes 3, 4, 5 sont répétées jusqu'à ce qu'un critère d'arrêt soit atteint (nombre d'itération ou le temps d'exécution par exemple).

Cet algorithme est particulièrement efficace pour trier les individus. En effet, le tri par degrés de dominance R réduit la complexité de calcul (Deb et al., 2002). L'utilisation de la distance foule d maintient une bonne diversité dans la population de solutions. Il est intéressant de préciser que l'utilisation d'une heuristique de réparation est envisageable pour s'assurer que l'ensemble E ne comporte que des solutions réalisables. L'algorithme NSGA-II a montré d'excellentes performances pour les problèmes comportant deux ou trois objectifs. Toutefois, lorsque le nombre d'objectifs devient élevé (au-delà de 3 ou 4), la capacité du tri par dominance décroît fortement.

Algorithme NSGA-III

Pour pallier aux limites de NSGA-II concernant les problèmes avec un nombre d'objectifs supérieur ou égal à 3, Zitzler et Künzli, 2004b ont introduit l'algorithme NSGA-III. Cette version conserve le mécanisme de tri par dominance non dominée de NSGA-II, mais remplace la distance de foule par un système de direction de référence (définition 7) défini à l'initialisation de l'algorithme.

Définition 7. *Dans un algorithme d'optimisation multiobjectif basé sur une population, comme NSGA-III, les* ***directions de référence*** *sont des vecteurs directionnels utilisés pour guider la sélection des solutions. Elles permettent une répartition uniforme de la population le long du front de Pareto (voir définition 5) en fournissant des directions de compromis dans l'espace objectif.*

Soit M le nombre d'objectifs, on définit un simplexe standard Δ^{M-1} de dimension $M-1$ comme l'enveloppe convexe des M vecteurs canoniques :

$$\Delta^{M-1} = \mathrm{Conv}\left\{e^{(1)}, e^{(2)}, \ldots, e^{(M)}\right\}$$

Un point de référence est un vecteur $r \in \mathbb{R}^M$ tel que :

$$r = (r_1, r_2, \ldots, r_M) \quad \textit{avec} \quad r_i \geqslant 0 \quad \textit{et} \quad \sum_{i=1}^{M} r_i = 1$$

Ces vecteurs r appartiennent au simplexe Δ^{M-1}. Leur répartition dans cet espace est contrôlée par différentes méthodes de génération :

- *Simplexe régulier discrétisé : méthode classique utilisée dans NSGA-III, où les vecteurs sont générés uniformément au sein du simplexe.*
- *Méthode hiérarchique de Das et Dennis : introduit des niveaux de précision (multi-résolution) pour améliorer la couverture de l'espace objectif.*
- *Échantillonnage uniforme sur la sphère : les directions sont d'abord générées sur la sphère unité puis projetées sur le simplexe.*
- *Méthodes aléatoires : les vecteurs sont tirés de manière stochastique sous la contrainte $\sum r_i = 1$, ce qui induit une couverture non structurée mais potentiellement plus variée.*

Le nombre de points de référence générés dépend du niveau de discrétisation choisi et peut largement dépasser M.

Au sein de l'espace objectif (définition 2) et durant la phase de sélection, ces points de référence (définition 7) guident le choix des solutions par l'algorithme. Chaque individu de la population est projeté sur l'un des points de référence. Ensuite l'algorithme sélectionne les individus associés à des points peu représentés ce qui favorise une bonne diversité dans la population.

1. **Initialisation** :
   - Génération d'une population initiale aléatoire.
   - Construction d'un ensemble de points de référence.
2. **Tri par domination non dominée** : identique à NSGA-II.
3. **Sélection** :
   - Pour le front partiel (lorsque le quota de population n'est pas encore atteint), les solutions sont affectées à leur point de référence le plus proche.
   - L'algorithme sélectionne les solutions les plus éloignées dans leur direction respective, pour assurer une bonne diversité.
4. **Croisement et mutation** : identiques à NSGA-II (ex. : SBX, mutation polynomiale).
5. **Répétition** : jusqu'à un critère d'arrêt fixé.

Conclusion

Les méthodes heuristiques jouent un rôle essentiel dans la résolution des problèmes multiobjectif complexes, notamment lorsque l'espace de recherche est vaste. L'algorithme NSGA-II constitue une

référence dans ce domaine grâce à son équilibre entre efficacité de convergence (via le tri par degré de dominance) et maintien de la diversité (grâce à la distance de foule).

Cependant, NSGA-II montre ses limites dès lors que le nombre d'objectifs devient élevé ($m > 3$). L'algorithme NSGA-III propose alors une alternative robuste en introduisant des points de référence, permettant une répartition plus uniforme des solutions le long du front de Pareto.

Ainsi, la distinction entre NSGA-II et NSGA-III illustre bien les évolutions récentes des algorithmes évolutifs multiobjectif, visant à améliorer la couverture et la représentativité des fronts approximés dans des contextes multi-critères de plus en plus complexes.

3 Projet EcoAlim

Afin de présenter ma contribution au projet EcoAlim, il est essentiel d'en retracer l'historique et de mettre en lumière les avancées scientifiques et méthodologiques déjà réalisées.

3.1 Historique

Le projet EcoAlim est né d'un besoin exprimé par la filière agricole : améliorer les bilans environnementaux liés à l'alimentation animale à l'échelle du cycle de vie complet. La méthode d'analyse du cycle de vie (ACV) permet de quantifier les impacts environnementaux d'un système (produit, service ou procédé) en prenant en compte l'ensemble des étapes de sa vie, de l'extraction des ressources à sa fin de vie (analyse « du berceau à la tombe »).

Conformément aux normes ISO et à la définition de la SETAC, une ACV se décompose en quatre phases :

— **Définition des objectifs et du système** : elle permet de poser le cadre de l'étude, de définir la fonction du système, l'unité fonctionnelle, et les limites du périmètre étudié.
— **Inventaire** : recensement et quantification des flux entrants et sortants (matières, énergie, émissions dans l'air, l'eau et le sol).
— **Évaluation des impacts** : traduction des flux inventoriés en impacts environnementaux à l'aide de modèles d'impact.
— **Interprétation** : analyse des résultats, identification des contributions majeures et des incertitudes, formulation de recommandations.

La publication du *rapport final du projet* (Espagnol et al., 2016) marque la première grande étape de valorisation du projet EcoAlim. Elle introduit une base de données environnementales dédiée aux matières premières françaises utilisées dans l'alimentation animale. Plus de 150 ingrédients y sont caractérisés selon des indicateurs ACV, et les données sont intégrées dans la base nationale *AGRIBALYSE*. Le rapport propose également un prototype d'outil de formulation multiobjectif, avec une application aux filières porcine, avicole et bovine.

Peu après, l'article Wilfart, Espagnol et al., 2016 et l'article Wilfart, Tailleur et al., 2017 diffusent en open source cette base de données. Elle élargit les périmètres d'analyse (champ, stockage, usine, port).

L'article Wilfart, Dusart et al., 2018 vulgarise les résultats du projet pour les acteurs de terrain. Il explique la démarche de formulation éco-responsable et illustre les compromis possibles entre objectifs économiques et environnementaux à l'aide d'approches multicritères.

La même année, Garcia-Launay et al., 2018a publie un article fondamental posant les bases de la modélisation multiobjectif dans ce contexte. En effet, cet article met en place la première méthode exacte de résolution, celle de somme pondérée (chapitre 2.2.2) et valide son efficacité sur plusieurs espèces.

Enfin, le rapport de stage de Crolard, 2018 applique concrètement les méthodes d'optimisation multiobjectif à l'élevage porcin et à l'aquaculture. Elle compare donc la méthode de pondération, d'ϵ-contraintes (section 2.2.2) et NSGAII. Ce rapport propose aussi d'autres méthodes de normalisation et initie l'utilisation d'algorithmes génétiques pour enrichir la recherche de solutions.

3.2 Présentation du projet EcoAlim

Nous reprenons ici le cadre mathématique présenté dans Garcia-Launay et al., 2018a, en l'adaptant à la problématique spécifique de l'alimentation porcine. Un élevage porcin se décompose classiquement

en deux grandes phases d'alimentations : le post-sevrage (aliments premier âge et deuxième âge) ainsi que l'engraissement (aliments de croissance et de finition).

Le projet *EcoAlim* se concentre principalement sur les phases de croissance (*Growing*) et de finition (*Finishing*), chacune présentant des objectifs nutritionnels et économiques spécifiques. La phase de croissance vise un développement rapide de la masse corporelle de l'animal, en s'appuyant sur des apports élevés en protéines digestibles et en énergie. Cette stratégie permet de maximiser le gain de poids tout en assurant une croissance musculaire optimale. En fin de cycle, la phase de finition a pour objectif de compléter la croissance tout en maîtrisant la prise de gras, facteur essentiel pour la qualité de la carcasse. À ce stade, la formule alimentaire est moins riche en protéines et en énergie, mais exige une gestion plus fine d'éléments clés tels que les fibres, le calcium et le phosphore. Cela assure le bon équilibre digestif et osseux de l'animal.

À chaque phase correspondent des besoins nutritionnels spécifiques, définis par des bornes minimales et maximales par kilo d'aliment. Sept nutriments clés sont pris en compte :

— **Protéines** (g/kg) : croissance musculaire.
— **Lysine** (g/kg) : acide aminé essentiel.
— **Méthionine** (g/kg) : second acide aminé limitant.
— **Phosphore** (g/kg) : développement osseux, attention à l'excès.
— **Calcium** (g/kg) : os et dentition.
— **Énergie** (MJ/kg) : apport calorique.
— **Fibres** (g/kg) : digestion.

Le fabricant d'aliment définit alors un aliment, composé de matières premières (céréales, co-produits, tourteaux, corps gras...). Pour chaque matière première, on connaît son coût, ses bornes d'incorporation, ses caractéristiques nutritionnelles, ainsi que ses impacts environnementaux (Wilfart, Espagnol et al., 2016, Garcia-Launay et al., 2018b).

Sept indicateurs environnementaux sont utilisés :

— **Changement climatique (CC)** : kg CO_2-eq.
— **Acidification (AC)** : molc H^+ eq.
— **Eutrophisation (EU)** : kg PO_4^{3-}-eq.
— **Demande en énergie (ENTOT)** : MJ non renouvelable.
— **Occupation des sols (OS)** : m^2.an.
— **Demande en phosphore (DP)** : kg P.

Le problème d'optimisation consiste donc à déterminer, pour une phase alimentaire donnée, un aliment qui respecte les contraintes nutritionnelles tout en minimisant le coût budgétaire (Coût) et les coûts environnementaux. Ce cadre se prête naturellement à une modélisation linéaire multiobjectif, que nous détaillerons dans la section suivante.

3.3 Formalisation du problème d'optimisation

Notre problème se définit formellement comme suit. Pour une phase alimentaire donnée, notons $\mathcal{J} = \{1, ..., J\}$ l'ensemble des j matières premières et $\mathcal{I}$ = l'ensemble des nutriments. Notons $Q_j^{\min}$ (resp. $Q_j^{\max}$) la borne minimale (resp. maximale) sur la matière première $j \in \mathcal{J}$ exprimée en kg. Notons $N_i^{\min}$ (resp. $N_i^{\max}$) la borne minimale (resp. maximale) sur le nutriment $i \in \mathcal{I}$ et n_{ij} l'apport d'1kg de matière première j en nutriment i.

Notons $\mathbf{x}$ un aliment décidé avec x_j le taux d'incorporation de la matière première $j \in J$. Notons $\mathcal{O} = \{\text{Coût}, \text{PD}, \text{CC}, \text{OS}, \text{AC}, \text{EU}, \text{EN}\}$ l'ensemble des objectifs du modèle. Avec pour chaque objectif :

$$f^m(\mathbf{x}) = \sum_{j \in J} c_j^m x_j$$

correspondant au coût de l'objectif $m \in \mathcal{O}$ pour l'aliment $\mathbf{x}$ avec c_j^m le coût de l'objectif m de la matière première j. Chaque aliment est donc évalué au travers de 7 objectifs, issus de l'ensemble $\mathcal{O}$.

Le problème consiste ainsi à déterminer un vecteur $x = (x_1, \ldots, x_n)$, représentant l'aliment à formuler, tel que : les quantités x_j respectent les bornes sur les matières premières : $Q_j^{\min} \leqslant x_j \leqslant Q_j^{\max}, \quad \forall j \in \mathcal{J}$, les apports nutritionnels satisfont les contraintes : $N_i^{\min} \leqslant \sum_{j \in J} n_{ij} x_j \leqslant N_i^{\max}, \quad \forall i \in \mathcal{I}$. Ce vecteur x constitue la solution de l'aliment optimal recherché.

3.4 Modélisation

Afin de représenter un aliment, prenons comme variable de décision $\mathbf{x} = \{x_1, ...x_j\}$ un aliment décidé avec x_j le taux d'incorporation de la matière première $j \in J$: $\{x_j \in [0,1], \quad \forall j \in \mathcal{J}\}$

Le programme linéaire pour ce problème est le suivant :

$$
\begin{aligned}
\min \sum_{j \in \mathcal{J}} c_j^{\text{Coût}} x_j, \\
\sum_{j \in \mathcal{J}} c_j^{\text{PD}} x_j, \\
\sum_{j \in \mathcal{J}} c_j^{\text{CC}} x_j, \\
\sum_{j \in \mathcal{J}} c_j^{\text{OS}} x_j, \\
\sum_{j \in \mathcal{J}} c_j^{\text{AC}} x_j, \\
\sum_{j \in \mathcal{J}} c_j^{\text{EU}} x_j, \\
\sum_{j \in \mathcal{J}} c_j^{\text{EN}} x_j,
\end{aligned}
$$

$$
\begin{aligned}
x_j &\geqslant Q_j^{\min}, && \forall j \in \mathcal{J} && (3.1)\\
x_j &\leqslant Q_j^{\max}, && \forall j \in \mathcal{J} && (3.2)\\
\sum_{j \in \mathcal{J}} n_{ij} x_j &\geqslant N_i^{\min}, && \forall i \in \mathcal{I} && (3.3)\\
\sum_{j \in \mathcal{J}} n_{ij} x_j &\leqslant N_i^{\max}, && \forall i \in \mathcal{I} && (3.4)\\
\sum_{j \in \mathcal{J}} x_j &= 1 && && (3.5)\\
x_j &\in [0,1], && \forall j \in \mathcal{J} &&
\end{aligned}
$$

Les contraintes 3.1 et 3.2 assurent un aliment solution qui respecte les bornes pour une matière première j donnée. Ces contraintes permettent d'assurer un aliment fiable pour l'animal (élaboration, ingestion et digestion).

Les contraintes 3.3 et 3.4 assurent un aliment solution qui respecte les bornes en nutriment i. Ces contraintes garantissent l'équilibrage d'un aliment en nutriment i pour l'animal.

La contrainte 3.5 garantit que le mélange alimentaire est composé correctement, avec toutes les proportions des ingrédients totalisant 100%, ce qui est nécessaire pour créer un aliment réalisable.

3.5 Bilan des contributions au projet EcoAlim

Dans cette section, et à partir d'un problème formalisé et modélisé précédemment, les approches de résolution déjà menées ainsi que leurs conclusions seront présentées, en s'appuyant sur le cadre mathématique introduit au chapitre 2.

3.5.1 Florence Garcia-Launay et al. (2018) : Multiobjective formulation is an effectivemethod to reduce environmental impacts of livestock feeds

Florence Garcia-Launay et al. (2018) propose d'utiliser, pour la résolution, la méthode de pondération (section 2.2.2). Afin d'agréger les objectifs, une normalisation est également introduite. De plus, le problème traité en 2018 comprend un sous ensemble d'objectifs $\mathcal{O} = \{\text{Coût}, \text{CC}, \text{PD}, \text{EN}, \text{OS}\}$.

Normalisation

Comme abordé dans la partie 2.1.4, la normalisation permet de comparer et de combiner différents objectifs sur une même échelle.

Soit $\mathcal{O}$ l'ensemble des objectifs. Notons $\tilde{s}^o_{o'}$ la valeur de l'objectif $o' \in \mathcal{O}$ obtenue par l'aliment $\tilde{x}^o$ calculé en résolvant le problème mono-objectif qui minimise l'objectif $o \in \mathcal{O}$, noté P_o, suivant :

$$P_o = \begin{cases} \min \quad f^o(x) & \\ \text{s.c. :} & \\ x_j \geqslant Q_j^{\min} & \forall j \in \mathcal{J} \\ x_j \leqslant Q_j^{\max} & \forall j \in \mathcal{J} \\ \sum_{j \in \mathcal{J}} n_{ij} \times x_j \geqslant N_i^{\min} & \forall i \in \mathcal{I} \\ \sum_{j \in \mathcal{J}} n_{ij} \times x_j \leqslant N_i^{\max} & \forall i \in \mathcal{I} \\ \sum_{j \in \mathcal{J}} x_j = 1 & \\ x_j \in [0,1] & \forall j \in \mathcal{J} \end{cases}$$

En posant $\tilde{x}^{\text{Coût}}$ l'aliment à moindre coût solution du problème $P_{\text{Coût}}$ et en reprenant les notations introduitent dans la partie 2.1.4, la normalisation proposée est la suivante :

$$C'_o = \frac{C_o}{\sum_{j \in \mathcal{J}} \tilde{x}_j^{\text{Coût}} \times c_j^o} \quad \forall o \in \mathcal{O}$$

Cette normalisation est centrée sur une référence métier concrète (l'aliment à moindre coût). Elle permet, après résolution, d'exprimer pour chaque objectif $o \in \mathcal{O}$ le ratio entre la performance environnementale de la solution x trouvée et celle obtenue avec l'aliment à moindre coût $\tilde{x}^{\text{Coût}}$.

Résolution

F. Garcia-Launay propose d'agréger les objectifs environnementaux et d'appliquer la méthode de pondération dans un espace objectif (définition 2) de dimension deux. En posant $\tilde{f}^{\text{env}}(x)$ la fonction environnementale agrégée avec les fonctions environnementales normalisées, et β le vecteur de pondération vérifiant $\sum_{o \in \mathcal{O}} \beta_o = 1$, l'agrégation est définie comme suit :

$$\tilde{f}^{\text{env}}(\mathbf{x}) = \beta_{\text{PD}} \tilde{f}^{\text{PD}}(\mathbf{x}) + \beta_{\text{CC}} \tilde{f}^{\text{CC}}(\mathbf{x}) + \beta_{\text{OS}} \tilde{f}^{\text{OS}}(\mathbf{x}) + \beta_{\text{EN}} \tilde{f}^{\text{EN}}(\mathbf{x})$$

Par ailleurs, pour limiter les effets de transfert de pollution, des contraintes supplémentaires sont introduites. On parle de transfert de pollution lorsqu'une amélioration d'un critère environnemental donné entraîne une dégradation simultanée d'un ou plusieurs autres critères environnementaux. Voici les contraintes ajoutées :

$$\sum_{j \in \mathcal{J}} x_j \times \tilde{c}_j^o \leqslant 1.05 \cdot \tilde{s}_o^{\text{Coût}} \quad \forall o \in \mathcal{O} \backslash \{\text{Coût}\} \tag{3.6}$$

La fonction objectif finale est une combinaison pondérée des impacts économiques et environnementaux. Voici le problème P_α, avec $\alpha \in \{0,1\}$ le poids donné à l'objectif coût :

$$P_\alpha = \begin{cases} \min\ \alpha \cdot \tilde{f}^{\text{Coût}}(x) + (1-\alpha) \cdot \tilde{f}^{\text{env}}(x) & \\ \text{s.c. :} & \\ x_j \geqslant Q_j^{\min} & \forall j \in \mathcal{J} \\ x_j \leqslant Q_j^{\max} & \forall j \in \mathcal{J} \\ \sum_{j \in \mathcal{J}} n_{ij} \times x_j \geqslant N_i^{\min} & \forall i \in \mathcal{I} \\ \sum_{j \in \mathcal{J}} n_{ij} \times x_j \leqslant N_i^{\max} & \forall i \in \mathcal{I} \\ \sum_{j \in \mathcal{J}} x_j = 1 & \\ \sum_{j \in \mathcal{J}} x_j \times \tilde{c}_j^o \leqslant 1.05 \cdot \tilde{s}_o^{\text{Coût}} & \forall o \in \mathcal{O} \backslash \{\text{Coût}\} \\ x_j \in [0,1] & \forall j \in \mathcal{J} \end{cases}$$

Avec $\alpha \cdot \tilde{f}^{\text{Coût}}(x) + (1-\alpha) \cdot \tilde{f}^{\text{env}}(x) = \alpha \cdot \sum_{j \in \mathcal{J}} \tilde{c}_j^{\text{Coût}} x_j + (1-\alpha) \cdot \sum_{j \in \mathcal{J}} x_j \cdot \sum_{o \in \mathcal{O} \backslash \{\text{Coût}\}} \beta_o \cdot \tilde{c}_j^o$

On remarque alors que le problème multiobjectif à 5 objectifs est transformé en un problème bi-objectif. La résolution correspond à une somme pondérée (section 2.2.2).

Choix des paramètres α et β_o. Le paramètre α contrôle l'arbitrage entre coût économique et impact environnemental. Afin d'étudier les compromis possibles, les auteurs font varier α dans l'intervalle $[0,1]$ par pas de 0,01. Pour chaque valeur de α, une solution optimale est calculée.

La solution finalement retenue correspond à une valeur spécifique α_{lim}, définie comme suit : C'est la plus petite valeur de α pour laquelle toute réduction supplémentaire de l'impact environnemental entraînerait une augmentation plus importante (en proportion) du coût. Autrement dit, au-delà de α_{lim}, améliorer encore les performances environnementales devient trop coûteux économiquement. Ce point représente un compromis raisonnable entre les deux dimensions du problème.

Concernant les coefficients de pondération environnementaux β_o, ceux-ci sont fixés et vérifient $\sum_{o \in \mathcal{O} \backslash \{\text{Coût}\}} \beta_o = 1$. Dans leur étude, $\beta_{\text{CC}} = 0.4$ tandis que les autres coefficients $(\beta_{\text{PD}}, \beta_{\text{NRE}}, \beta_{\text{LO}})$ valent chacun 0.2. Ce choix reflète une pondération plus forte accordée au critère de changement climatique.

Conclusion

Cette approche présente certaines limites. La normalisation peut favoriser la réduction d'impacts ayant une forte variabilité (grande différence entre la valeur minimale et la référence), ce qui peut biaiser l'optimisation. De plus, l'agrégation réduit le problème à un unique compromis, alors qu'un ensemble de solutions pertinentes pourrait exister. Enfin, le choix des pondérations reste subjectif, influençant fortement la solution finale.

Malgré ces limites, l'approche proposée est robuste et opérationnelle : elle permet de concilier performance économique et soutenabilité environnementale dans une logique de compromis.

3.5.2 Cécile Crolard (2018) : Formulation multiobjectif d'aliments pour truites et porcs en croissance

Lors de son stage, C. Crolard (2018) reconsidère le problème en ajoutant dans la formulation multi-objectif, deux objectifs environnementaux : acidification et l'eutrophisation. Elle reprend la démarche proposée par F. Garcia-Launay consistant à agréger les objectifs environnementaux afin de transformer le problème multiobjectif en un problème bi-objectif. De plus, C. Crolard propose une nouvelle méthode de normalisation ainsi qu'un algorithme génétique NSGA-II pour la résolution.

Normalisation

Afin d'agréger les objectifs environnementaux entre eux, il est nécessaire de les normaliser. En reprenant les notations précédentes, avec $\tilde{s}_{o'}^o$ la valeur de l'objectif o' obtenue par l'aliment $\tilde{x}^o$ issu du problème mono-objectif P_o, la normalisation proposée est :

$$C'_o = \frac{C_o - \tilde{s}_o^o}{\tilde{s}_o^{\text{Coût}} - \tilde{s}_o^o} \quad \forall o \in \mathcal{O}\backslash\{\text{Coût}\}, \quad C'_{\text{Coût}} = \frac{C_{\text{Coût}}}{\tilde{s}_{\text{Coût}}^{\text{Coût}}}$$

Cette transformation permet d'assurer une pondération plus équitable entre les objectifs.

Résolution

C. Crolard reformule le problème avec la même approche proposée par F. Garcia-Launay, voici le problème :

$$\begin{aligned}
&\min\ (f^{\text{Coût}}(x), \tilde{f}^{\text{env}}(x)) \\
&\text{s.c. :} \\
&\quad x_j \geqslant Q_j^{\min} && \forall j \in \mathcal{J} \\
&\quad x_j \leqslant Q_j^{\max} && \forall j \in \mathcal{J} \\
&\quad \sum_{j \in \mathcal{J}} n_{ij} \times x_j \geqslant N_i^{\min} && \forall i \in \mathcal{I} \\
&\quad \sum_{j \in \mathcal{J}} n_{ij} \times x_j \leqslant N_i^{\max} && \forall i \in \mathcal{I} \\
&\quad \sum_{j \in \mathcal{J}} x_j = 1 \\
&\quad \sum_{j \in \mathcal{J}} x_j \times \tilde{c}_j^o \leqslant 1.05 \cdot \tilde{s}_o^{\text{Coût}} && \forall o \in \mathcal{O}\backslash\{\text{Coût}\} \\
&\quad x_j \in [0,1] && \forall j \in \mathcal{J}
\end{aligned}$$

D'après Jozefowiez, 2013a, l'algorithme NSGA-II (partie 2.2.3) est théoriquement pertinent pour la résolution de problème biobjectif. L'intérêt réside dans sa capacité à produire directement un échantillon diversifié de solutions non dominées, en évitant les biais d'exploration liés aux méthodes scalaires (pondération, contraintes fixes). Cependant, l'application de NSGA-II à ce problème a rapidement montré ses limites. La dimension continue de l'espace de décision, avec une quarantaine d'ingrédients à ajuster, complique fortement la convergence de l'algorithme. De plus, les nombreuses contraintes nutritionnelles et d'incorporation couplées restreignent fortement la part de solutions admissibles.

Malgré un nombre élevé d'évaluations (jusqu'à 90 000 sur certaines simulations), NSGA-II n'a pas permis d'atteindre des solutions de qualité comparable à celles obtenues par programmation linéaire. Les meilleures solutions générées restent systématiquement dominées par les solutions issues des méthodes scalaires mises en œuvre.

Au regard de ces performances insuffisantes dans ce contexte spécifique, l'utilisation de NSGA-II n'a pas été poursuivie dans la suite de ce travail.

Conclusion

C. Crolard observe une répartition plus homogène des efforts de réduction entre les différents indicateurs environnementaux. L'effet de compensation est également atténué, ce qui évite qu'un seul indicateur masque les autres. Toutefois, comme pour la méthode de F. Garcia-Launay, la solution reste sensible au choix arbitraire des pondérations.

L'ajout d'une phase expérimentale avec l'algorithme NSGA-II a permis d'explorer une approche non scalaire. Néanmoins, les performances obtenues sont restées limitées, notamment du fait de la complexité du problème, de la forte dimension de l'espace de décision et de la présence de nombreuses contraintes strictes. Ces difficultés n'ont pas permis au NSGA-II de produire un front compétitif par rapport aux méthodes exactes dans ce cadre.

3.6 Conclusion

Les approches de F. Garcia-Launay et C. Crolard s'appuient sur une formulation scalaire bi-objectif : coût économique versus impact environnemental global. De plus, l'utilisation d'un vecteur de pondération permet aux décideurs de favoriser l'amélioration de certains objectifs et ainsi mieux répondre aux besoins ciblés.

Toutefois, cette réduction à un espace objectif de dimension deux présente des limites structurelles. En effet, cette modélisation réduit la diversité des solutions et ainsi des compromis possibles. De plus, l'influence du décideur sur les solutions par la pondération ne permet pas de rendre compte de la vrai nature du problème.

Dans le chapitre suivant, je vais vous présenter ma contribution au projet EcoAlim. Ma démarche est motivée par l'envie de considérer chaque objectif et ainsi définir un front de Pareto plus uniforme. Ainsi, cette démarche rendra compte de l'ensemble des compromis possibles.

4 Contributions

En tant qu'alternant à l'IFIP – Institut du Porc, ma mission vise à contribuer à la mise en place d'un outil de formulation alimentaire optimisée, conciliant performance économique et soutenabilité environnementale.

Ce chapitre s'inscrit dans la continuité des travaux menés par Garcia-Launay et Crolard sur la formulation alimentaire multiobjectif dans le cadre du projet EcoAlim. Il a pour objectif d'approfondir l'analyse du compromis entre performance économique et impacts environnementaux, en s'appuyant sur la modélisation multiobjectif présentée à la section 3.4.

L'approche proposée ici intègre simultanément l'ensemble des sept objectifs définis. Du fait que les fonctions objectif sont linéaires et que les contraintes définissent un ensemble admissible convexe, le problème est convexe. Cela garantit, en théorie, que le front de Pareto est convexe dans l'espace des objectifs. Dès lors, la méthode de pondération à poids positifs ou nul permet d'obtenir l'ensemble des solutions supportées.

Dans ce travail, seules les solutions strictement Pareto-optimales sont considérées. Plus précisément, la procédure de filtrage (*is_pareto*) utilisée identifie les solutions non dominées au sens strict (définition 3). Les solutions faiblement efficaces ne sont donc pas prises en compte dans l'analyse (définition 4).

4.1 Introduction

En reprenant la modélisation présentée en section 3.4, j'applique la méthode de la somme pondérée pour sa résolution. Cette combinaison entre la modélisation initiale et la méthode de pondération sera désignée par *SP1* dans la suite de ce document.

Par la suite, en m'inspirant des travaux de F. Garcia-Launay, j'intègre à la modélisation des contraintes supplémentaires visant à limiter les effets de transfert de pollution (voir équation 3.6). Cette nouvelle formulation, couplée à la méthode de la somme pondérée, sera référencée sous l'intitulé *SP2*.

Afin de permettre une comparaison des méthodes et des normalisations, l'ensemble des expérimentations a été conçu avec un nombre d'itérations équivalent pour chaque approche. Le nombre total de combinaisons générées est fixé à 12 376 solutions par méthode, garantissant une charge computationnelle homogène et une exploration des fronts de Pareto comparable.

Dans les méthodes *SP1* et *SP2*, les vecteurs de pondérations sont générés de manière exhaustive sur le simplexe $\Delta^7 = \{\lambda \in \mathbb{R}^7 \ : \ \sum_{j=1}^{7} \lambda_j = 1, \ \lambda_j \geqslant 0\}$. Cette discrétisation s'appuie sur un découpage régulier de l'intervalle $[0, 1]$ en N niveaux pour chaque pondération en imposant la contrainte :

$$\sum_{j=1}^{7} \frac{k_j}{N} = 1, \qquad k_j \in \{0, 1, \ldots, N\}.$$

Le problème revient ainsi à générer l'ensemble des combinaisons de pondérations de somme 1, ce qui garantit une couverture régulière et homogène du simplexe unitaire. Dans cette étude, la valeur $N = 11$ a été utilisée pour un total de $\binom{N+7-1}{7-1} = \binom{17}{6} = 12376$ vecteurs distincts de pondérations.

Chaque vecteur ainsi obtenu sert directement à construire une instance du problème de formulation multiobjectif. Il assure une exploration de l'ensemble des compromis pondérés.

Par ailleurs, dans certaines méthodes de projection biobjectives (notamment *Garcia* et *Crolard*), le vecteur de pondérations environnementales β permet d'agréger les six objectifs environnementaux en un score unique. Ce vecteur a été fixé de manière uniforme, avec des pondérations identiques pour chaque

objectif environnemental. Ce choix vise à neutraliser l'effet des préférences pondérées du décideur et à isoler les effets structurels des formulations mathématiques sur la répartition des solutions.

4.2 Métriques d'évaluation multiobjectif

L'évaluation de la qualité des fronts de Pareto générés repose sur un ensemble strict de métriques issues de la littérature récente en optimisation multiobjectif. Les travaux de Audet et al., 2021 constituent ici la référence méthodologique centrale. Ces travaux offrent une synthèse des indicateurs de performance disponibles pour apprécier la qualité d'un front de Pareto. Dans la suite, nous présentons la sélection restreinte des indicateurs retenus, les ajustements méthodologiques effectués, ainsi que leur rôle respectif dans l'analyse comparative des fronts générés.

4.2.1 Fondements généraux

Selon Audet et al., 2021, les indicateurs de performance se structurent autour de quatre dimensions analytiques fondamentales : cardinalité, convergence, dispersion (spread) et distribution (uniformity). L'objectif dans ce travail n'est pas de mesurer la cardinalité brute, ni de vérifier la convergence par rapport à un front de référence inconnu. L'accent est mis sur des indicateurs de dispersion et de distribution permettant d'évaluer la qualité de la couverture (i.e. des fronts de Pareto) obtenue dans l'espace objectif.

Avant l'évaluation des indicateurs, les solutions issues des fronts de Pareto sont systématiquement normalisées. Cette normalisation, indépendante de celle employée lors de la génération des fronts, est effectuée selon l'une des deux procédures projet (*Crolard* ou *Garcia*). Dans la suite, toute solution du front de Pareto sera notée $y \in \mathcal{Y} \subset \mathbb{R}^m$. Après normalisation projet (*Crolard* ou *Garcia*), on notera $\hat{y}$ la solution correspondante dans l'espace objectif normalisé. L'espace objectif normalisé désigne l'ensemble des solutions après application d'une normalisation du projet (*Crolard* ou *Garcia*). Les métriques sont toutes calculées dans cet espace homogène afin de garantir l'indépendance des indicateurs vis-à-vis des unités et des échelles des critères (i.e. des objectifs).

4.2.2 Indice DCI (Directional Coverage Index)

L'indicateur DCI ou σ vise à quantifier la capacité d'un front de Pareto à explorer uniformément l'ensemble des directions de compromis au sein de l'espace objectif multidimensionnel.

Chaque solution normalisée est ensuite projetée sur la sphère unité $S^{m-1} \subset \mathbb{R}^m$. Cette projection est définie par :

$$\tilde{y} = \frac{\hat{y}}{\|\hat{y}\|},$$

où $\|\hat{y}\|$ désigne la norme euclidienne (ou norme ℓ_2), donnée par :

$$\|\hat{y}\| = \sqrt{\sum_{j=1}^{m} \hat{y}_j^2}.$$

Cette opération permet de repositionner l'ensemble des solutions sur la sphère unité ce qui élimine toute influence résiduelle des échelles initiales, et garantit l'impartialité des mesures angulaires.

Sur cette sphère S^{m-1}, un ensemble $\mathcal{D} = \{d_i\}_{i=1}^{P}$ de directions aléatoires uniformes est généré, avec $P = 1000$ dans le cadre de cette étude. Chaque direction d_i est considérée comme couverte si au moins une solution projetée s'en approche suffisamment angulairement, c'est-à-dire si :

$$\exists\, \tilde{y} \in \mathcal{Y} \quad \text{tel que} \quad \cos^{-1}\left(\langle \tilde{y}, d_i \rangle\right) \leqslant \theta.$$

L'angle seuil θ est relié à un paramètre de tolérance d par :

$$\cos(\theta) \geqslant 1 - \frac{d^2}{2},$$

avec ici $d = 0.5 \rightarrow \theta \approx 28.6°$. Plus l'angle θ est restreint, plus la condition de couverture devient stricte.

L'indicateur directionnel de couverture σ est alors formellement défini comme le ratio de directions couvertes sur l'ensemble généré :

$$\sigma = \frac{\#\{d_i \in \mathcal{D} \,|\, \exists\, \tilde{y} \in \mathcal{Y} \text{ tel que } \cos^{-1}(\langle \tilde{y}, d_i \rangle) \leqslant \theta\}}{P}.$$

Dans la suite du projet, afin de garantir la comparabilité des résultats produits par la métrique DCI, une même graine aléatoire sera systématiquement utilisée.

Interprétation graphique : La figure suivante illustre le principe de couverture directionnelle sur la sphère unité (ici S^1 dans le cas particulier à deux dimensions). Les points bleus matérialisent les directions aléatoires générées $\{d_i\}$. Le vecteur rouge plein illustre une direction donnée associée à une solution projetée, tandis que les deux segments rouges pointillés définissent les bornes angulaires du cône de couverture associé à θ. Une direction est considérée comme couverte si elle appartient à ce cône angulaire centré sur une solution du front projeté. Dans notre exemple, une des quatres directions est couverte.

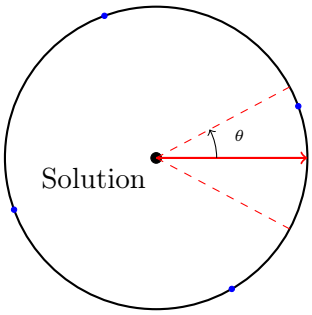

FIGURE 4.1 – Illustration du principe de couverture directionnelle sur la sphère unité (S^1 ici pour $m = 2$).

4.2.3 Énergie de Riesz

L'indicateur d'énergie de Riesz ou E_s quantifie la concentration locale des points dans l'espace objectif. Il permet d'évaluer la régularité spatiale de la répartition des solutions au sein du front de Pareto.

Comme précédemment, les solutions du front de Pareto considérées $y \in \mathcal{Y} \subset \mathbb{R}^m$ sont préalablement normalisées selon la procédure projet (*Crolard* ou *Garcia*).

L'énergie de Riesz est alors calculée directement sur ces points normalisés, selon la définition classique de l'énergie s-Riesz :

$$E_s = \sum_{i=1}^{n} \sum_{\substack{j=1 \\ j \neq i}}^{n} \frac{1}{\|\hat{y}_i - \hat{y}_j\|^s},$$

où n est le nombre total de solutions, et $\|\hat{y}_i - \hat{y}_j\|$ désigne la distance euclidienne entre les points normalisés :

$$\|\hat{y}_i - \hat{y}_j\| = \sqrt{\sum_{k=1}^{m} (\hat{y}_{ik} - \hat{y}_{jk})^2}.$$

Le paramètre d'ordre s contrôle la pondération relative des paires de points proches versus éloignés. Des valeurs élevées de s augmentent la pénalisation des solutions jugées trop proches. Conformément aux recommandations de Hardin et al., 2002, un compromis numérique robuste a été retenu avec $s = 1.5$ dans cette étude.

Une énergie E_s faible traduit une bonne répartition homogène des solutions dans l'espace objectif normalisé, tandis qu'une énergie élevée signale des concentrations excessives de solutions dans certaines régions du front.

4.2.4 Dispersion moyenne et extension maximale

Les indicateurs dispersion moyenne ou M_2 et extension maximale ou M_3 visent à caractériser l'étendue du front de Pareto dans l'espace objectif.

Le calcul est réalisé sur les solutions normalisées $\hat{y}$.

L'indicateur M_2 mesure la dispersion moyenne inter-points, et est défini par :

$$M_2 = \frac{2}{n(n-1)} \sum_{i<j} \|\hat{y}_i - \hat{y}_j\|,$$

où n désigne le nombre total de solutions considérées.

L'indicateur M_3 quantifie l'étendue maximale du front :

$$M_3 = \max_{i,j} \|\hat{y}_i - \hat{y}_j\|.$$

Le premier renseigne sur l'éloignement moyen des solutions, le second sur l'amplitude maximale couverte indépendamment de la répartition interne.

4.2.5 Indice PCI (Performance Comparison Indicator)

L'indicateur PCI, proposé par Li et al., 2015, vise à évaluer simultanément la dispersion et la couverture effective des solutions dans l'espace objectif.

L'espace objectif normalisé est discrétisé selon une grille régulière de paramètre g, ici fixé à $g = 4$. Cette grille partitionne l'espace en g^m cellules hypercubiques égales (soit $4^7 = 16384$ boîtes dans le présent cas à sept objectifs).

Chaque cellule C_k est déclarée couverte si au moins une solution normalisée $\hat{y}$ y est présente. L'indicateur PCI est alors défini comme le ratio du nombre de cellules effectivement couvertes sur le nombre total de cellules possibles :

$$PCI = \frac{\#\text{cellules couvertes}}{g^m}.$$

Interprétation graphique : La figure suivante illustre le principe du calcul du PCI dans le cas bidimensionnel ($m = 2$) pour $g = 4$. L'espace est discrétisé en 16 cellules carrées. Les cellules en bleu indiquent les boîtes où au moins une solution normalisée est présente. Les points noirs représentent les solutions individuelles situées dans l'espace objectif. On observe ici la nature binaire (cellule vide ou couverte) du PCI mais qui permet néanmoins d'appréhender la répartition globale des solutions sur l'espace objectif. Une valeur élevée de PCI traduit une exploration étendue et relativement uniforme du domaine de Pareto, tandis qu'une valeur faible reflète une dispersion restreinte et localisée.

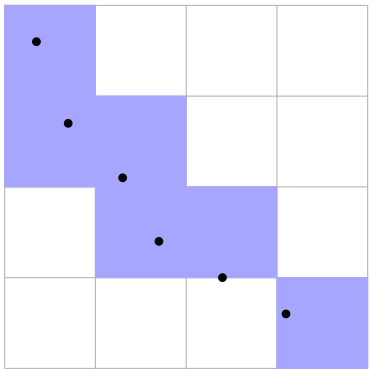

Illustration 2D, $g = 4$: cellules couvertes (PCI) et points Pareto-optimaux (minimisation).

FIGURE 4.2 – Front de Pareto (minimisation) et cellules de la grille occupées pour le calcul du PCI.

4.2.6 Paramètres de calcul et adaptations expérimentales

Conformément à la complexité du problème étudié, les valeurs suivantes ont été retenues :
— $s = 1.5$ pour E_s (Riesz energy),
— $d = 0.5$ pour σ (DCI),
— $g = 4$ pour le PCI,
— Normalisation préalable systématique des objectifs avant tout calcul de métrique pour évaluer la robustesse des métriques aux transformations.

Ce cadre rigoureux permet une comparaison des différentes méthodes de génération de fronts et des normalisations, en distinguant précisément les notions de diversité, d'étendue et de régularité spatiale.

4.3 Analyse comparative des normalisations de génération des fronts

L'objectif de cette section est d'évaluer l'influence des procédures de normalisation projet (*Crolard* et *Garcia*) appliquées en amont lors de la génération des fronts de Pareto, indépendamment de la normalisation ultérieure utilisée pour le calcul des métriques. L'analyse est menée distinctement sur chacune des deux phases (*Growing* et *Finishing*). Les tableaux des performances sont le fruit de la moyenne de chaque méthode et pour chaque métrique par la normalisation projet (*Crolard* et *Garcia*).

4.3.1 Résultats sur la phase Growing

Les performances moyennes obtenues sur la phase *Growing* sont synthétisées dans le tableau suivant :

Normalisation	σ	E_s (Riesz)	M_2	M_3	PCI
Crolard	0.671	1.54×10^{25}	0.611	1.578	0.306
Garcia	0.658	1.61×10^{25}	0.598	1.582	0.361

Table 4.1 – Performances moyennes selon la normalisation projet - Phase Growing.

Sur la phase *Growing*, la normalisation *Crolard* génère des fronts présentant une meilleure dispersion angulaire (σ) et une répartition plus homogène des solutions (E_s), traduisant ainsi une répartition spatiale supérieure dans l'espace objectif. La normalisation *Garcia* favorise quant à elle une étendue légèrement supérieure des fronts (M_2, M_3) ainsi qu'une occupation plus dense de l'espace discrétisé (PCI).

4.3.2 Résultats sur la phase Finishing

Les résultats sur la phase *Finishing* sont présentés dans le tableau suivant :

Normalisation	σ	E_s (Riesz)	M_2	M_3	PCI
Crolard	0.645	4.48×10^{24}	0.588	1.555	0.305
Garcia	0.651	7.65×10^{24}	0.545	1.554	0.355

Table 4.2 – Performances moyennes selon la normalisation projet - Phase Finishing.

On observe des tendances similaires à la phase *Growing* : *Crolard* continue de produire des fronts mieux répartis (valeurs inférieures de E_s), tandis que *Garcia* conserve un léger avantage sur les mesures d'extension et de couverture discrète (PCI).

Synthèse comparative

L'analyse croisée confirme que la normalisation projet influence significativement la structure des fronts obtenus. Les différences observées sur les deux phases sont cohérentes et stables :
— la normalisation *Garcia* favorise une occupation étendue du volume objectif, maximisant la couverture discrète (PCI) ;

— la normalisation *Crolard* améliore la régularité interne des fronts et la dispersion angulaire, critères centraux pour la qualité géométrique du front.

L'objectif est d'obtenir des fronts diversifiés et homogènes. La normalisation *Crolard* est retenue comme procédure de normalisation principale pour l'ensemble des analyses ultérieures. Afin de représenter simultanément les différentes métriques au sein des graphiques radar figure 4.3, chaque indicateur est préalablement mis à l'échelle par une normalisation min-max indépendante, appliquée sur l'ensemble des fronts considérés. Pour une métrique donnée X, la valeur normalisée X_{norm} est calculée selon :

$$X_{\text{norm}} = \frac{X - \min_j X_j}{\max_j X_j - \min_j X_j},$$

où X_j désigne la valeur de la métrique X sur le front j. Cette transformation, strictement destinée à la visualisation graphique, permet une lecture comparative cohérente sur les radars.

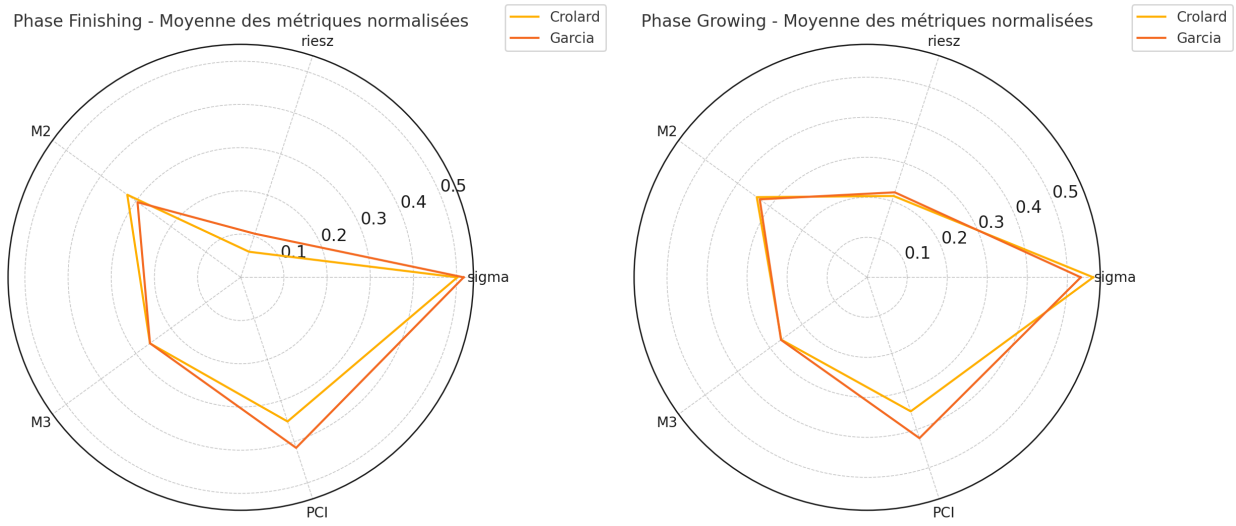

FIGURE 4.3 – Comparaison visuelle des normalisations de génération par radar pour chaque phase.

4.4 Analyse comparative des méthodes de génération des fronts de Pareto

Après avoir sélectionné la normalisation proposée par C. Crolard comme cadre d'évaluation (cf. section précédente), cette section propose une analyse comparative des différentes méthodes de génération des fronts de Pareto. L'objectif est d'évaluer la capacité de chaque méthode à produire des fronts diversifiés, réguliers et couvrant efficacement l'espace objectif multicritère. Les méthodes étudiées diffèrent à la fois par la nature des méthodes de résolutions employées (ϵ-contrainte, pondération) et par la structure des espaces objectifs sur lesquels elles opèrent (biobjectif ou multiobjectif dans $\mathbb{R}^7$).

Les méthodes de génération sont comparées entre elles pour les deux phases de formulation. Cette distinction est justifiée par la nature différente des contraintes opérationnelles et nutritionnelles. Elles modifient donc la structure géométrique des fronts de Pareto selon la phase considérée. L'analyse s'appuie sur l'ensemble des indicateurs métriques présentés précédemment.

4.4.1 Résultats sur la phase Growing

Les méthodes comparées reposent sur des résolutions algorithmiques distinctes. Elles induisent donc des structures de fronts de Pareto différentes.

Méthode Garcia

D'après la table 4.3, la méthode *Garcia* repose sur une agrégation pondérée fixe des six objectifs environnementaux. Le problème initial est réduit à un problème biobjectif $(\widetilde{f}_{\text{Coût}}, \widetilde{f}_{\text{env}})$. Les solutions

obtenues s'alignent principalement sur certaines directions privilégiées de compromis, définies par α. Cette restriction structurelle de l'espace objectif explique la faible dispersion angulaire (σ), la dispersion modérée (M_2, M_3), et la couverture discrète partielle (PCI). La régularité spatiale interne (Riesz) est relativement correcte du fait de la densification locale autour de quelques configurations privilégiées.

Méthode Crolard

D'après la table 4.3, la méthode *Crolard* utilise une approche ϵ-contrainte dans l'espace biobjectif projeté. Cette méthode génére des fronts localisés autour des solutions de coût minimal sous des contraintes budgétaires croissantes. Ce fonctionnement induit une dispersion encore plus restreinte que *Garcia* (M_2, M_3, PCI très faibles), mais une régularité interne stable (Riesz) due à l'alignement progressif des solutions le long d'une trajectoire unique de compromis fortement contrainte.

Méthodes SP1 et SP2

D'après la table 4.3, les méthodes *SP1* et *SP2* explorent directement l'espace objectif complet sans réduction de dimension préalable. Elles présentent des fronts étendus (M_2, M_3 élevés), une couverture directionnelle large (σ proche de 0.77), et une occupation discrète très élevée de l'espace (PCI significativement supérieur aux autres approches). La méthode *SP2* montre un compromis légèrement plus équilibré entre extension et régularité spatiale (Riesz inférieur à *SP1*) ce qui traduit une meilleure dispersion des points sur l'ensemble des compromis accessibles.

Les indicateurs numériques associés sont synthétisés dans le tableau suivant :

Méthode	σ	E_s (Riesz)	M_2	M_3	PCI
SP1	0.771	4.07×10^{25}	0.974	3.005	0.684
SP2	0.740	2.09×10^{25}	0.613	1.219	0.463
Crolard	0.637	2.55×10^{11}	0.356	1.044	0.043
Garcia	0.536	1.53×10^{4}	0.502	1.044	0.035

Table 4.3 – Indicateurs de performance sur la phase Growing (moyenne des normalisations métriques).

Synthèse comparative des méthodes sur la phase Growing

L'analyse des résultats met en évidence des différences entre les familles de méthodes testées.

Les méthodes *SP1* et *SP2*, opérant directement dans l'espace objectif complet à sept dimensions, génèrent des fronts de Pareto significativement plus étendus et diversifiés. Les indicateurs de dispersion (M_2, M_3), de couverture directionnelle (σ) et de couverture discrète (PCI) y atteignent leurs niveaux les plus élevés. Cette capacité d'exploration globale découle directement de la génération de vecteurs de pondérations multiobjectif sur le simplexe complet. Cette génération permet de représenter un spectre large de compromis sans réduction préalable de dimension. Entre les deux variantes, *SP2* présente une légère supériorité en termes de régularité spatiale (valeurs de E_s inférieures). Ces résultats traduient une répartition plus homogène des solutions le long du front.

En comparaison, les méthodes *Crolard* et *Garcia*, qui ramènent le problème à une structure biobjectif projetée, produisent des fronts sensiblement plus restreints dans l'espace complet. La méthode *Crolard* génère des solutions alignées le long d'une trajectoire de compromis pilotée par la contrainte progressive sur l'impact budgétaire (ϵ-contrainte). Cette exploration latérale des compromis multiobjectif accessibles dans l'espace global explique la faible dispersion (M_2, M_3) et la couverture discrète minimale (PCI). La méthode *Garcia*, bien qu'elle offre une dispersion légèrement supérieure, reste contrainte par la structure scalaire de pondération appliquée sur les objectifs environnementaux agrégés.

Globalement, ces résultats confirment l'intérêt des formulations multiobjectif complètes lorsque l'objectif est de capturer une diversité large et homogène de compromis, et soulignent les limites intrinsèques des méthodes bi-objectives projetées dans l'espace objectif.

4.4.2 Résultats sur la phase Finishing

Les méthodes comparées présentent des comportements différents dans un contexte de contraintes modifiées, propres à la phase *Finishing*. Les changements de structure du problème (contraintes nutritionnelles et limites d'incorporation spécifiques) influencent directement la géométrie des fronts de Pareto produits.

Méthode Garcia

D'après la table 4.4, la méthode *Garcia* applique, comme précédemment, une agrégation pondérée fixe des six objectifs environnementaux, réduisant le problème à un biobjectif projeté $(\widetilde{f}_{\text{Coût}}, \widetilde{f}_{\text{env}})$. Dans ce contexte *Finishing*, les solutions générées se concentrent sur un nombre de configurations restreint. L'espace admissible dans $\mathbb{R}^2$ limite davantage la dispersion angulaire ($\sigma = 0.468$) et l'extension globale ($M_2 = 0.475$, $M_3 = 1.054$). La couverture discrète ($PCI = 0.034$) reste faible et l'homogénéité spatiale (Riesz) demeure modérée, avec $E_s = 1.88 \times 10^4$.

Méthode Crolard

D'après la table 4.4, avec l'approche ϵ-contrainte appliquée dans l'espace biobjectif projeté, la méthode *Crolard* conserve un comportement similaire à celui observé en phase *Growing*. La progression des solutions le long de la contrainte économique produit un front étroit, faiblement dispersé ($M_2 = 0.318$, $M_3 = 1.056$), avec une occupation de l'espace objectif toujours très restreinte ($PCI = 0.049$). Toutefois, la régularité interne des solutions reste satisfaisante, avec un E_s maintenu à 2.41×10^{11}.

Méthodes SP1 et SP2

D'après la table 4.4, les formulations *SP1* et *SP2* conservent leur capacité à explorer efficacement l'espace objectif complet malgré les nouvelles contraintes spécifiques à la phase *Finishing*. Les fronts générés restent étendus ($M_2 = 0.867$ pour *SP1* et 0.604 pour *SP2* ; M_3 de 2.811 et 1.297 respectivement). La couverture directionnelle demeure élevée ($\sigma \approx 0.77$ pour *SP1*, 0.733 pour *SP2*), de même que l'occupation discrète (PCI de 0.699 et 0.539). *SP2* continue de présenter une meilleure régularité spatiale (Riesz réduit à 9.40×10^{24} contre 1.49×10^{25} pour *SP1*) ce qui confirme une meilleure homogénéité des compromis obtenus.

Les indicateurs numériques correspondants sont récapitulés dans le tableau suivant :

Méthode	σ	E_s (Riesz)	M_2	M_3	PCI
SP1	0.774	1.49×10^{25}	0.867	2.811	0.699
SP2	0.733	9.40×10^{24}	0.604	1.297	0.539
Crolard	0.618	2.41×10^{11}	0.318	1.056	0.049
Garcia	0.468	1.88×10^4	0.475	1.054	0.034

TABLE 4.4 – Indicateurs de performance sur la phase Finishing (moyenne des normalisations métriques).

Synthèse comparative des méthodes sur la phase Finishing

Les résultats observés sur la phase *Finishing* confirment globalement les tendances identifiées sur la phase *Growing*. Les méthodes *SP1* et *SP2* maintiennent leur supériorité en termes de diversité et de dispersion des solutions, avec des extensions importantes (M_2, M_3), une bonne couverture directionnelle (σ), et une occupation discrète élevée (PCI). *SP2* conserve son avantage en régularité interne (Riesz inférieur).

Les méthodes projetées bi-objectives *Crolard* et *Garcia* montrent des limitations similaires à celles observées sur *Growing* : faibles dispersions, couverture directionnelle partielle et PCI réduits. L'espace admissible plus restreint accentue encore cette réduction de diversité, notamment pour *Garcia* qui reste concentré autour de quelques configurations privilégiées définies par la pondération fixe α.

Ainsi, la capacité des méthodes multiobjectif complètes à capturer une diversité riche de compromis multi-dimensionnels est d'autant plus manifeste sur la phase *Finishing*.

Synthèse générale des performances des méthodes de génération

L'ensemble des analyses réalisées sur les deux phases confirme des comportements différenciés très marqués entre les familles de méthodes considérées. Les approches multiobjectif complètes (*SP1* et *SP2*), opérant directement dans l'espace objectif à sept dimensions, démontrent une capacité supérieure à explorer la diversité des compromis disponibles. Cette capacité d'exploration se traduit par des valeurs élevées sur les indicateurs de dispersion (M_2, M_3), de couverture directionnelle (σ), et de couverture discrète (PCI).

Entre ces deux variantes, la méthode *SP2* parvient à préserver un compromis légèrement plus homogène en termes de répartition spatiale des solutions (valeurs de Riesz inférieures). Ces résultats traduisent un équilibre optimal entre diversité et régularité interne. Cette homogénéité peut être attribuée aux contraintes supplémentaires qui stabilisent la dispersion autour de zones de compromis intermédiaires mieux équilibrées.

Les méthodes bi-objectives projetées (*Garcia* et *Crolard*) présentent en revanche des limites structurelles plus importantes. La réduction initiale à un espace de dimension deux par pondération fixe (*Garcia*) ou par ϵ-contrainte (*Crolard*) restreint la variété des solutions générées et limite la couverture de l'espace objectif complet. La méthode *Crolard* apparaît comme la plus restrictive, avec des extensions et une occupation discrète très faibles, tandis que *Garcia* permet une dispersion légèrement plus large mais reste fortement contrainte dans ses orientations de compromis.

Au global, ces résultats confirment de manière robuste que les formulations multiobjectif complètes. En évitant toute réduction préalable de dimension, ces formulations sont les plus efficaces pour approcher la diversité structurelle et géométrique d'un problème multiobjectif environnemental complexe tel que EcoAlim.

Tentative exploratoire avec un algorithme évolutionnaire (NSGA-III)

Dans le cadre des expérimentations complémentaires, l'algorithme NSGA-III a été implémenté afin d'évaluer sa capacité à générer des fronts de Pareto compétitifs sur le problème EcoAlim. Cet algorithme constitue une référence fréquente dans la littérature d'optimisation multicritère stochastique.

Toutefois, malgré plusieurs réglages de paramètres (taille de population, nombre de générations, stratégie de croisement et de mutation), les solutions générées par NSGA-III se sont toujours révélées dominées par les fronts produits via les méthodes exactes déterministes (*SP1*, *SP2*, *Crolard*, *Garcia*). Aucun des points obtenus avec NSGA-III n'a contribué à étendre le front global, ni à capturer des régions du compromis multiobjectif non couvertes par les méthodes exactes.

Cette domination s'explique principalement par la nature fortement contraint et convexe du problème EcoAlim, où les formulations exactes permettent une exploration exhaustive et déterministe des compromis. Les méthodes évolutionnaires, plus adaptées aux problèmes non convexes ou de grande complexité combinatoire, apparaissent ici surdimensionnées et moins pertinentes dans ce contexte très bien modélisé.

En conséquence, les résultats issus de NSGA-III n'ont pas été intégrés dans les calculs d'indicateurs de performance précédents.

4.5 Synthèse finale sur la méthode et la normalisation recommandées

L'ensemble des résultats expérimentaux conduit à identifier la méthode *SP2* comme l'approche la plus performante et la plus robuste pour le projet EcoAlim. Cette méthode permet de capturer efficacement l'ensemble des compromis multiobjectif accessibles. Son léger avantage en régularité spatiale, confirmé par des valeurs d'énergie de Riesz inférieures à celles de *SP1*, renforce sa capacité à produire des fronts équilibrés et homogènes.

Concernant la normalisation en amont des méthodes de génération, la normalisation *Crolard* s'est avérée la plus adaptée. Cette normalisation permet une génération robuste et homogène des solutions Pareto optimales, indépendamment de la méthode de génération utilisée.

Ces choix méthodologiques seront retenus comme base de référence pour les développements ultérieurs de l'outil d'aide à la formulation EcoAlim.

5 Approfondissement de l'analyse multi-objectif

L'analyse comparative conduite sur l'ensemble des méthodes de génération a permis d'identifié comme base la méthode *SP2* pour l'analyse menée dans ce chapitre.

L'objectif de cette section est d'examiner plus finement la structure interne des solutions générées par *SP2*. Cette analyse vise à étudier la dispersion géométrique des compromis dans l'espace objectif complet à sept dimensions puis la diversité des profils de solutions extrêmes et intermédiaires ainsi que les interactions internes entre les différentes dimensions environnementales et économiques. Cette analyse permet d'éclairer la richesse structurelle du front obtenu et d'apporter une lecture plus détaillée des compromis sous-jacents présents dans le problème EcoAlim.

Les résultats présentés s'appuient sur les solutions générées indépendamment sur les deux phases (*Growing* et *Finishing*), en cohérence avec les contraintes propres à chaque contexte de formulation.

5.1 Analyse quantitative de la variabilité interne du front

L'analyse de la dispersion interne des solutions générées par la méthode *SP2* permet de caractériser finement la diversité des compromis atteints dans l'espace objectif complet. Au-delà des représentations visuelles, la variabilité des solutions est ici quantifiée à travers deux indicateurs classiques : l'écart-type et l'amplitude des valeurs atteintes pour chaque objectif.

Sur la phase *Growing*, la dispersion demeure élevée sur les grandes dimensions environnementales et économiques. L'écart-type atteint 7.89€ pour le coût, 22.93 kg $CO_2 - eq$ pour les émissions de gaz à effet de serre (CC), et 572.33 MJ sur la consommation d'énergie (ENTOT). Les amplitudes maximales sur ces mêmes dimensions confirment l'étendue des compromis obtenus, respectivement de 35.80, 108.56 et 1552.07. Sur les objectifs liés à la consommation de phosphore, à l'eutrophisation et à l'acidification, les dispersions restent notables quoique plus modérées. Ces résultats traduisent des marges de compromis environnementaux partiellement corrélés aux solutions extrêmes de formulation.

En phase *Finishing*, les tendances observées restent similaires, mais des différences apparaissent sur certaines dimensions spécifiques. L'amplitude de variation sur l'occupation des sols (Occup Sols) diminue sensiblement (352.09 à 217.81), tout comme celle observée sur l'eutrophisation (0.919 à 0.759). Ces contractions reflètent l'effet des contraintes nutritionnelles propres à la phase *Finishing*. Elles restreignent plus fortement certaines configurations de formulation et limitent les marges de manœuvre sur ces dimensions. À l'inverse, les variations sur la demande en énergie (ENTOT) et sur le coût restent largement préservées ce qui confirme la robustesse de la méthode *SP2* à maintenir une diversité de compromis, même sous des contraintes nutritionnelles plus restrictives.

Cette première analyse quantitative de la variabilité interne du front *SP2* met en évidence la richesse et l'étendue des compromis accessibles. De plus elle souligne certaines directions de dispersion plus ou moins contraintes selon la nature des objectifs et la phase de formulation étudiée. Ces observations quantitatives fourniront une base d'appui aux analyses multidimensionnelles ultérieures.

5.2 Analyse multidimensionnelle par représentations en coordonnées parallèles

L'analyse multidimensionnelle des solutions issues de la méthode *SP2* est poursuivie à travers la représentation des fronts de Pareto en coordonnées parallèles. Cette représentation permet de visualiser

simultanément la répartition des solutions sur l'ensemble des objectifs considérés. Chaque solution est représentée par une trajectoire reliant ses niveaux atteints sur les différents objectifs. Ainsi cette représentation offre une lecture directe de la variabilité et des interactions internes entre critères.

Sur la phase *Growing*, les représentations obtenues mettent en évidence une dispersion généralisée des solutions sur l'ensemble des objectifs. Les trajectoires observées illustrent la diversité des profils de formulation générés par *SP2*, avec des configurations variant depuis des solutions économiques minimales jusqu'à des compromis environnementaux fortement engagés. Les variations simultanées sur les émissions de gaz à effet de serre (CC), la demande en énergie (ENTOT) et l'occupation des sols (Occup Sols) sont particulièrement marquées ce qui confirme la richesse des stratégies de formulation explorées. Certains profils de solutions traduisent des arbitrages directs entre ces dimensions environnementales. Ces solutions mettent en lumière les synergies et conflits structurels du problème EcoAlim.

La figure 5.1 illustre cette dispersion multidimensionnelle obtenue sur la phase *Growing*.

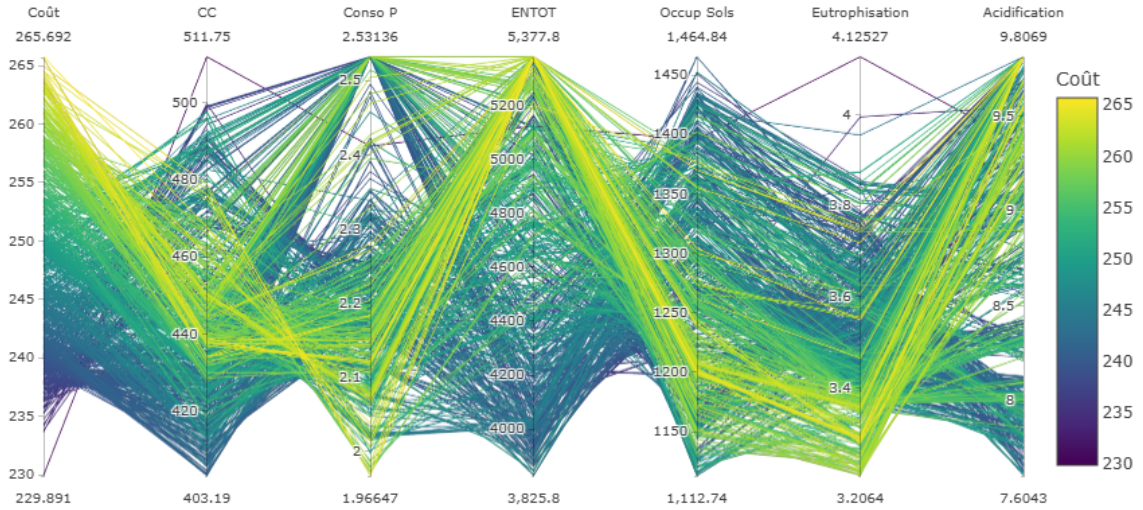

FIGURE 5.1 – Représentation en coordonnées parallèles des solutions SP2 - Phase Growing.

La phase *Finishing* présente une organisation interne globalement similaire, mais avec quelques différences structurelles induites par les contraintes nutritionnelles spécifiques à cette phase. Certaines trajectoires environnementales apparaissent légèrement plus resserrées, en particulier sur la consommation de phosphore (Conso P) et l'eutrophisation. Ces restrictions traduisent le rétrécissement partiel de l'espace admissible. Ces résultats confirme la capacité de *SP2* à générer des configurations diversifiées sur l'ensemble des dimensions environnementales.

La figure 5.2 présente de manière analogue la distribution des solutions sur la phase *Finishing*.

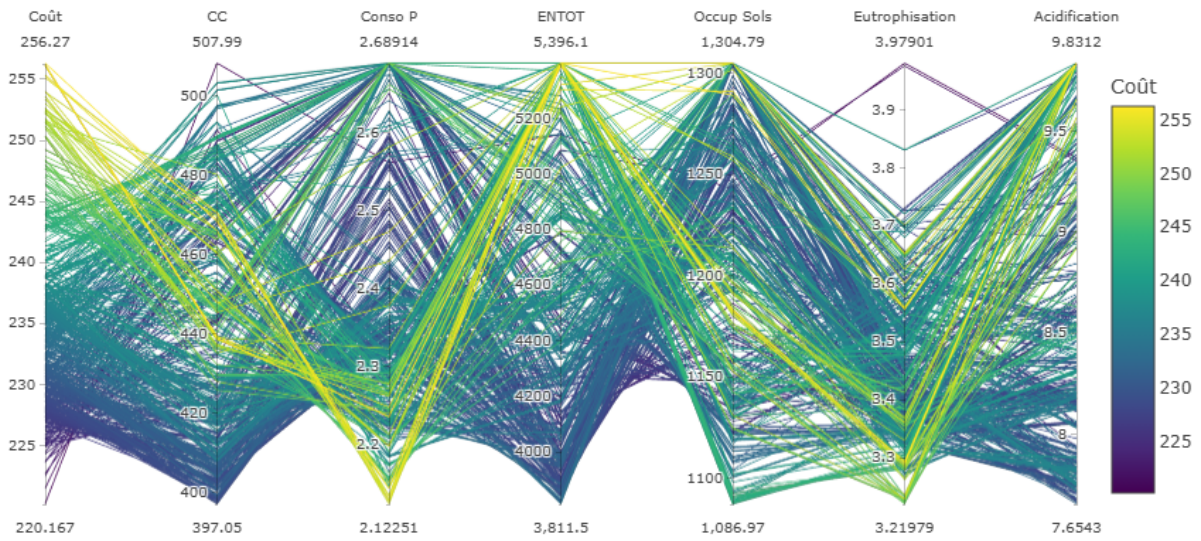

FIGURE 5.2 – Représentation en coordonnées parallèles des solutions SP2 - Phase Finishing.

L'exploitation de ces représentations parallèles offre une lecture approfondie de la structure interne du front *SP2*. Elles mettent en évidence les interactions croisées entre certains objectifs ainsi que la richesse des compromis atteints.

5.3 Analyse des solutions extrêmes

L'analyse des solutions extrêmes permet de caractériser les configurations limites atteignables par la méthode *SP2* sur chacun des objectifs étudiés. Cette approche vise à identifier, pour chaque critère, la solution réalisant la meilleure performance individuelle, tout en observant simultanément l'impact de ces optimisations locales sur les autres dimensions objectives. Ainsi, chaque extrême représente un scénario de compromis maximal en faveur d'un objectif donné, et permet d'apprécier les tensions existantes entre les différentes objectifs environnementales et économiques du problème.

La table 5.1 présente les valeurs atteintes pour chacun des objectifs (colonnes) lorsque ceux-ci sont minimisés individuellement (lignes), dans le cadre de la phase *Growing*. Chaque ligne correspond à une solution obtenue en minimisant exclusivement un objectif donné (indiqué en première colonne), tandis que les colonnes 2 à 8 indiquent les valeurs prises par l'ensemble des fonctions objectif pour cette solution. La solution économique pure minimise le coût à 229.89, mais demeure associée à des niveaux élevés sur plusieurs objectifs environnementaux, notamment les émissions de gaz à effet de serre (511.75), la demande en énergie (5121.75) et l'eutrophisation (4.13). À l'inverse, l'optimisation de chaque objectif environnemental produit des dégradations variables sur le plan économique. Par exemple, la solution minimisant le CC (403.19) est obtenue pour un coût de 241.28, tandis que la réduction de la demande en énergie (3825.77) s'accompagne d'un coût de 245.94. Certains objectifs environnementaux, tels que l'eutrophisation et l'acidification, présentent des effets de contrepartie plus marqués avec des coûts associés respectivement de 259.79 et 247.11. Ces résultats traduisent des tensions spécifiques entre ces dimensions et la performance économique.

Objectif extrême	Coût	CC	Conso P	Demande en énergie	Occup Sols	Eutrophisation	Acidification
Coût	**229.89**	511.75	2.41	5121.75	1395.08	4.13	9.34
CC	241.28	**403.19**	2.34	3907.23	1370.60	3.49	7.97
Conso P	264.87	478.64	**1.97**	5377.84	1369.62	3.75	9.81
Demande en énergie	245.94	421.96	2.21	**3825.77**	1354.87	3.59	8.74
Occup Sols	248.35	490.01	2.53	5377.84	**1112.74**	3.43	9.81
Eutrophisation	259.79	451.96	2.53	5263.00	1159.74	**3.21**	9.37
Acidification	247.11	441.05	2.53	4718.55	1404.79	3.61	**7.60**

TABLE 5.1 – Valeurs des objectifs pour les solutions extrêmes — Phase Growing.

D'après la table 5.2 sur la phase *Finishing*, les profils extrêmes conservent des structures similaires, mais avec des différences liées aux contraintes nutritionnelles spécifiques de cette phase. La solution de coût minimal atteint 220.17, légèrement inférieure à la phase *Growing*, tandis que les extrêmes environnementaux restent globalement proches en termes d'amplitudes atteintes. On observe néanmoins des étendues plus faibles sur certaines dimensions, notamment sur l'occupation des sols et la consommation de phosphore ce qui confirme l'effet restrictif des contraintes de formulation propres à cette phase. Les compromis observés entre objectifs demeurent toutefois équilibrés et comparables aux observations réalisées sur *Growing*.

Objectif extrême	Coût	CC	Conso P	Demande en énergie	Occup Sols	Eutrophisation	Acidification
Coût	**220.17**	507.99	2.56	5139.18	1242.65	3.98	9.36
CC	229.13	**397.05**	2.42	3874.19	1304.79	3.39	7.85
Conso P	253.90	470.20	**2.12**	5396.14	1304.79	3.65	9.83
Demande en énergie	234.20	412.68	2.34	**3811.51**	1304.79	3.50	8.51
Occup Sols	242.65	489.56	2.69	5396.14	**1086.97**	3.30	9.83
Eutrophisation	247.95	446.11	2.66	4953.47	1152.35	**3.22**	9.52
Acidification	232.30	420.12	2.69	4047.23	1304.79	3.40	**7.65**

TABLE 5.2 – Valeurs des objectifs pour les solutions extrêmes — Phase Finishing.

L'analyse de ces solutions extrêmes met ainsi en évidence la structure interne des tensions multiobjectif du problème EcoAlim. Les optimisations ciblées sur une dimension environnementale donnée induisent systématiquement des dégradations différentielles sur les autres critères. Cette structure conflictuelle intrinsèque justifie pleinement le recours à une approche multiobjectif globale telle que *SP2* pour capturer l'ensemble des compromis accessibles.

5.4 Corrélations et interactions entre objectifs

L'analyse des interactions croisées entre objectifs est conduite à partir des matrices de corrélation de Pearson, calculées sur l'ensemble des solutions générées par la méthode *SP2* pour les phases *Growing* et *Finishing*. Cette approche permet de mettre en évidence les relations structurelles existantes entre les différentes dimensions environnementales et économiques du problème.

D'après la table 5.3 sur la phase *Growing*, plusieurs relations marquées émergent. Le coût est fortement corrélé à la demande énergétique totale (Énergie Totale, $r = 0.759$) et de manière plus modérée aux émissions de gaz à effet de serre (CC, $r = 0.288$). Ces corrélations traduisent le fait qu'une amélioration de la performance économique reste globalement associée à des formulations moins énergétiques, avec un effet indirect sur les émissions de GES (gaz à effet de serre, i.e. CC). L'acidification est également corrélée au coût ($r = 0.456$) et plus encore à CC ($r = 0.710$), confirmant la proximité de ces dimensions dans la structure environnementale du modèle. À l'inverse, l'occupation des sols présente des relations inverses avec ces mêmes dimensions ($r = -0.427$ avec le coût et $r = -0.621$ avec CC). Ces relations soulignent l'existence de tensions multiobjectif sur l'occupation des sols dans les formulations les plus favorables économiquement et climatiquement.

	Coût	CC	Conso P	Énergie Totale	Occup Sols	Eutrophisation	Acidification
Coût	1.000	0.288	-0.201	0.759	-0.427	-0.555	0.456
CC	0.288	1.000	0.025	0.715	-0.621	0.094	0.710
Conso P	-0.201	0.025	1.000	-0.040	-0.160	-0.349	-0.278
Énergie Totale	0.759	0.715	-0.040	1.000	-0.692	-0.358	0.562
Occup Sols	-0.427	-0.621	-0.160	-0.692	1.000	0.606	-0.738
Eutrophisation	-0.555	0.094	-0.349	-0.358	0.606	1.000	-0.180
Acidification	0.456	0.710	-0.278	0.562	-0.738	-0.180	1.000

TABLE 5.3 – Matrice de corrélation entre objectifs — Phase Growing.

D'après la table 5.4, la phase *Finishing* confirme globalement ces structures relationnelles, tout en amplifiant certains effets. Les corrélations entre coût et énergie totale ($r = 0.791$), ainsi qu'entre CC et énergie totale ($r = 0.815$) traduisent un couplage renforcé entre charge énergétique et coût sous contraintes nutritionnelles resserrées. L'acidification devient très fortement associée aux émissions de GES ($r = 0.858$) et à l'énergie totale ($r = 0.767$) ce qui met en lumière des interactions environnementales plus prononcées sous l'effet des restrictions spécifiques de la phase *Finishing*. En revanche la consommation de phosphore et l'eutrophisation demeurent relativement décorrélées des autres dimensions, avec des coefficients restant faibles à modérés. Ce constat traduit une relative autonomie de ces impacts vis-à-vis des autres compromis.

	Coût	CC	Conso P	Énergie Totale	Occup Sols	Eutrophisation	Acidification
Coût	1.000	0.437	-0.224	0.791	-0.359	-0.228	0.633
CC	0.437	1.000	0.199	0.815	-0.782	0.165	0.858
Conso P	-0.224	0.199	1.000	-0.019	-0.433	-0.557	-0.060
Énergie Totale	0.791	0.815	-0.019	1.000	-0.718	-0.079	0.767
Occup Sols	-0.359	-0.782	-0.433	-0.718	1.000	0.367	-0.694
Eutrophisation	-0.228	0.165	-0.557	-0.079	0.367	1.000	0.132
Acidification	0.633	0.858	-0.060	0.767	-0.694	0.132	1.000

TABLE 5.4 – Matrice de corrélation entre objectifs — Phase Finishing.

Ces structures de corrélations internes confirment l'existence de sous-systèmes d'objectifs partiellement couplés à l'intérieur du problème EcoAlim. Elles justifient pleinement le recours à une exploration multidimensionnelle complète pour représenter adéquatement la diversité des compromis atteignables, et soulignent la complexité intrinsèque des arbitrages environnementaux et économiques sous-jacents à la formulation alimentaire.

5.5 Extension de l'algorithme Greedy Reduction aux contraintes économiques

L'algorithme Greedy Reduction (GR), proposé par Venkat et al. Venkat et al., 2004, constitue un outil de post-optimalité conçu pour extraire un sous-ensemble représentatif de solutions Pareto dans des problèmes multiobjectif complexes. Plutôt que de rechercher des pondérations explicites ou des agrégations des objectifs, la méthode repose sur l'utilisation de vecteurs de rang calculés individuellement sur chaque objectif. Chaque solution du front est ainsi caractérisée par son niveau relatif de performance sur chaque critère.

L'approche consiste ensuite à sélectionner les solutions qui présentent les meilleurs scores agrégés selon une fonction de score composite Cette procédure permet d'identifier un échantillon réduit de solutions globalement bien positionnées sur l'ensemble des objectif.

Dans le contexte de l'application EcoAlim, cette procédure a été adaptée afin d'intégrer les contraintes économiques propres au contexte industriel. En pratique, les solutions conservées doivent respecter un seuil de coût maximal $C_{\max}$ fixé par le décideur donc une contrainte budgétaire stricte.

L'algorithme modifié procède ainsi en deux étapes. Une phase de filtrage préalable élimine l'ensemble des solutions dont le coût excède la contrainte $C_{\max}$ spécifiée. La procédure Greedy Reduction est ensuite appliquée sur l'ensemble réduit ainsi obtenu. Cette extension permet de produire un sous-ensemble de solutions multiobjectif à la fois équilibrées sur le plan environnemental et admissibles sur le plan économique.

L'introduction de cette borne budgétaire confère à la procédure GR une adaptabilité directe aux exigences pratiques des décideurs, tout en préservant la robustesse du mécanisme multiobjectif initial.

Conclusion du chapitre d'approfondissement

L'analyse approfondie de la structure interne du front *SP2* conduite dans ce chapitre a permis de caractériser en détail la diversité des compromis multiobjectif générés sur le problème EcoAlim. Les différentes analyses abordées ont mis en évidence la richesse géométrique du front généré et la complexité intrinsèque des interactions entre objectifs économiques et environnementaux.

Ces résultats offrent une vision complète des tensions multiobjectif en présence et permettent au décideur d'identifier à la fois les marges de manœuvre exploitables et les objectifs en conflit. La diversité des profils atteints par *SP2* garantit une représentation robuste de l'espace de compromis atteignable.

L'introduction de la procédure de réduction Greedy étendue avec l'ajout d'une contrainte budgétaire sous la forme d'un seuil de coût maximal $C_{\max}$, permet de filtrer efficacement le front généré en fonction du contexte industriel. Ce mécanisme de post-sélection multicritère permet de restituer un sous-ensemble de solutions économiquement admissibles et équilibrées sur le plan environnemental. Ces solutions sont directement mobilisables pour orienter les choix de formulation.

Ainsi, la combinaison d'une génération exhaustive de compromis via *SP2* et d'une procédure de filtrage flexible par Greedy Reduction constitue un dispositif décisionnel complet, robuste et adaptable aux réalités industrielles de formulation alimentaire durable.

6 Analyse de la sensibilité aux pondérations dans la génération des fronts

Dans ce chapitre, nous étudirons d'abord l'effet du nombre d'itérations (i.e. de pondérations testées) sur la taille du front obtenu. L'objectif sera de mettre en évidence dans quelle mesure l'enrichissement du maillage permet de découvrir de nouveaux points Pareto optimales. Nous analyserons ensuite la répartition des pondérations associées aux points Pareto optimales. Ces pondérations sont qualifiées comme contributives pour la suite.

L'implémentation a été réalisée sur un ordinateur portable Dell Latitude 5420, équipé d'un processeur Intel Core i5-1135G7 (11 génération, 4 coeurs, 8 threads, 2.40 GHz), de 8 Go de mémoire RAM et fonctionnant sous Windows 11 Professionnel (version 10.0.26100).

6.1 Impact du nombre d'itérations sur la taille du front

Dans cette section, on s'intéresse à la proportion des itérations ayant effectivement conduit à un point de Pareto optimal au sens strict. Pour cela, on fait varier N dans l'ensemble $\{1, 2, \ldots, 11\}$ et on mesure, pour chaque configuration, le taux de vecteurs de pondération associés à une solution appartenant au front de Pareto. Il est important de noter que l'objectif est de maximiser N afin d'obtenir un front de Pareto aussi riche et diversifié que possible.

Résultats sur la phase Growing

Pour chaque valeur de $N \in \{1, \ldots, 11\}$, la méthode *SP2* est utilisée pour générer un ensemble de $\binom{N+6}{6}$ vecteurs de pondérations, chacun donnant lieu à la résolution d'un problème d'optimisation. L'ensemble de solution obtenue est ensuite vérifié pour définir le front de Pareto.

La figure 6.1 présente, pour chaque valeur de N, le pourcentage de points Pareto optimales ainsi que le temps total d'exécution requis. On observe une décroissance rapide du taux de points (i.e., des itérations) utiles : pour $N \in \{1, 2, 3\}$, plus de 80 % des itérations conduisent à un point du front, contre moins de 20 % pour $N \in \{10, 11\}$. Ce constat met en évidence un effet de saturation du maillage : au-delà d'un certain seuil, l'augmentation de la granularité n'améliore que marginalement la couverture du front.

En parallèle, le temps de calcul croît fortement avec N. À titre d'exemple, le passage de $N = 1$ à $N = 11$ fait passer le nombre d'itérations de 7 à 12 376, pour un temps d'exécution allant de moins d'une seconde à plus de 20 minutes.

Ces résultats permettent d'identifier une zone de compromis entre précision et coût de calcul, située à $N = 8$ pour la phase de Growing.

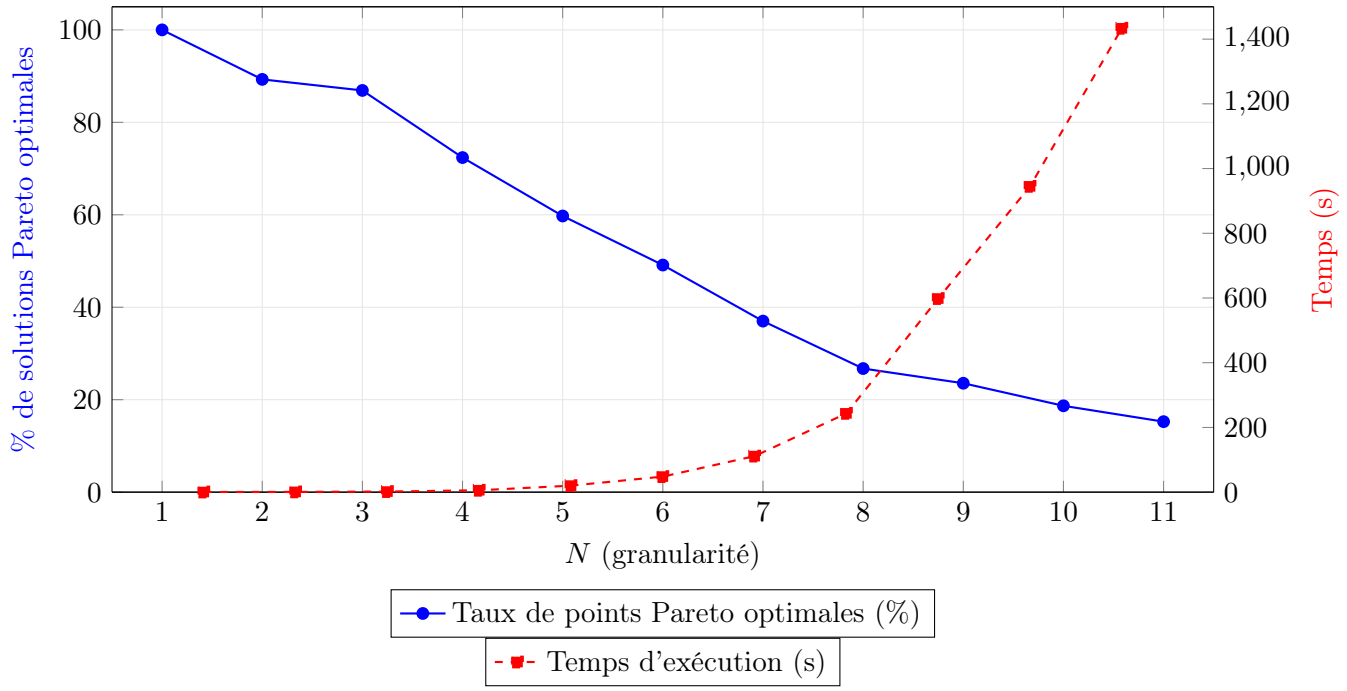

FIGURE 6.1 – Taux de solutions Pareto optimales et temps d'exécution en fonction de la granularité N (phase Growing)

Résultats sur la phase Finishing

La phase *Finishing* repose sur la même méthode *SP2*. Pour chaque valeur de $N \in \{1, \ldots, 11\}$, on génère à nouveau $\binom{N+6}{6}$ pondérations, et on évalue la proportion de solutions non dominées obtenues, ainsi que le temps de calcul requis.

La figure 6.2 montre que, bien que le taux de solutions utiles soit globalement inférieur à celui observé en phase *Growing*, les tendances restent similaires. Pour $N \leqslant 3$, plus de 80 % des itérations produisent un point du front, tandis qu'au-delà de $N = 8$, cette proportion descend en dessous de 20 %. La phase *Finishing* présente donc une efficacité décroissante similaire à mesure que la granularité augmente.

En parallèle, le temps d'exécution croît fortement, notamment à partir de $N = 6$, avec un coût de calcul multiplié par un facteur supérieur à 100 entre les extrêmes. Ce comportement confirme l'existence d'un effet de saturation du maillage, et renforce la conclusion établie précédemment : au-delà de $N = 8$, le gain marginal devient négligeable au regard du temps investi.

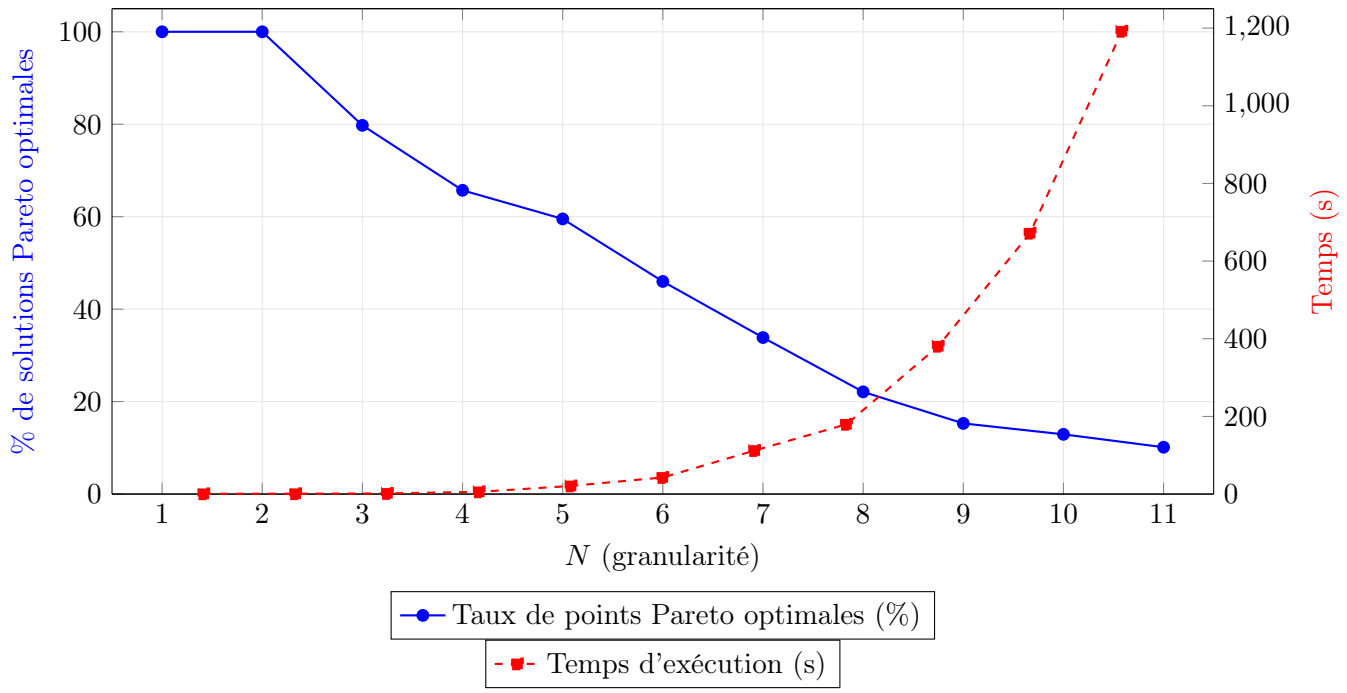

FIGURE 6.2 – Taux de solutions Pareto optimales et temps d'exécution en fonction de la granularité N (phase Finishing)

Synthèse : influence de la granularité

Les résultats obtenus sur les phases *Growing* et *Finishing* montrent un phénomène commun : le taux de solutions non dominées décroît rapidement avec N, tandis que le temps d'exécution croît fortement.

Dans les deux phases, plus de 80 % des pondérations testées sont pertinentes pour $N \leqslant 3$, mais ce taux chute à environ 15 % pour $N = 11$. Parallèlement, le temps de calcul est multiplié par plus de 100 entre les extrêmes. Ce comportement illustre un effet de saturation du maillage : au-delà d'un certain seuil, l'enrichissement de la grille apporte peu de nouveaux points au front de Pareto.

Ces observations suggèrent un compromis optimal entre couverture du front et coût de calcul autour de $N = 8$, seuil à partir duquel les gains en diversité deviennent marginaux par rapport au temps d'exécution.

6.2 Répartition des pondérations contributives

Cette section analyse l'influence des vecteurs de pondérations appliqués dans *SP2* sur la diversité des solutions générées. La granularité est fixée à $N = 8$, soit 3003 itérations par phase.

Il convient de souligner que les pondérations retenues résultent à la fois des contraintes internes du problème EcoAlim et du mécanisme de filtrage (*is_pareto* introduit au chapitre 4) appliqué lors de la construction du front. La méthode *SP2* étant exacte, plusieurs pondérations distinctes peuvent conduire à une même solution Pareto optimale. Lors de la suppression des doublons, seule la première pondération rencontrée est conservée pour représenter chaque solution. Cependant, cette selection (*first*) introduit ainsi un biais qui tend à privilégier les configurations présentant davantage de composantes proches de 0, souvent situées en début de l'ordre de génération combinatoire.

Afin de nuancer cette lecture, une seconde analyse est également conduite à partir de la dernière pondération rencontrée pour chaque solution. Cette variante (*last*) permet d'atténuer le biais introduit par l'ordre de génération, en capturant des configurations potentiellement plus équilibrées. Elle offre ainsi un point de comparaison utile pour évaluer la robustesse des répartitions observées.

Résultats sur la phase Growing

L'analyse de la sensibilité aux pondérations appliquée à la phase *Growing* s'appuie sur les 803 solutions non dominées extraites parmi les 3003 itérations réalisées avec $N = 8$. Le tableau 6.1 présente, pour chaque niveau discret $\lambda_i \in \{0, \frac{1}{8}, \ldots, 1\}$, la distribution des pondérations retenues par objectif, selon les deux critères de sélection.

Table 6.1 – Distribution des pondérations retenues sur la phase Growing, selon la règle de sélection (first ou last)

λ_i	Coût	CC	Conso P	ENTOT	Occup Sols	Eutrophisation	Acidification
Sélection ***first***							
0.000	37.98	54.42	53.05	44.08	34.37	47.70	37.73
0.125	25.28	27.27	30.51	25.78	26.77	21.54	24.41
0.250	14.69	10.59	10.46	16.81	15.07	14.32	14.82
0.375	8.59	5.23	4.36	6.85	13.57	8.72	11.33
0.500	7.35	1.12	1.62	3.61	6.10	5.35	5.85
0.625	3.86	0.87	0.00	1.49	2.74	1.62	3.49
0.750	1.62	0.37	0.00	1.00	0.75	0.62	1.62
0.875	0.50	0.12	0.00	0.37	0.50	0.12	0.62
1.000	0.12	0.00	0.00	0.00	0.12	0.00	0.12
Sélection ***last***							
0.000	37.98	54.05	52.80	44.46	35.24	47.70	37.48
0.125	25.28	26.90	30.76	25.90	26.03	21.54	24.66
0.250	14.69	10.59	10.46	16.69	14.94	14.32	14.69
0.375	8.59	5.60	4.36	7.60	13.57	8.72	11.46
0.500	7.35	1.37	1.62	2.49	6.10	5.35	5.60
0.625	3.86	1.00	0.00	1.62	2.74	1.62	3.61
0.750	1.62	0.37	0.00	0.87	0.75	0.50	1.74
0.875	0.50	0.12	0.00	0.37	0.50	0.25	0.62
1.000	0.12	0.00	0.00	0.00	0.12	0.00	0.12

Dans les deux cas, la distribution est fortement concentrée autour des faibles pondérations. La classe $\lambda_i = 0$ domine largement pour la plupart des objectifs environnementaux. Par exemple, plus de 54% des solutions sont générées sans pondération sur le critère CC, et plus de 44% sans pondération sur ENTOT. Ce phénomène traduit une activation sélective des objectifs, dans laquelle certains sont temporairement écartés au profit d'autres lors de la construction des compromis.

À l'opposé, les pondérations maximales ($\lambda_i = 1$) sont quasi absentes pour tous les objectifs, confirmant que les solutions strictement monoobjectif ne sont pas nécessaires pour atteindre les extrêmes du front.

La comparaison entre *first* et *last* met en évidence une répartition très stable. Quelques écarts sont observés pour les niveaux intermédiaires, notamment $\lambda_i = 0.375$ et 0.500, légèrement plus fréquents en version *last*. Ce léger décalage reflète une attribution de pondérations marginalement plus équilibrées en fin de génération du simplexe unitaire. Toutefois, la structure globale reste inchangée : les solutions contributives sont majoritairement issues de pondérations nulles ou modérées, centrées autour de $\lambda_i \leqslant 0.5$.

L'objectif économique (Coût) se distingue par une répartition plus étalée : les pondérations nulles ne concernent que 38% des cas, et les niveaux intermédiaires conservent un poids significatif. Cela confirme que le coût reste intégré dans la plupart des compromis, sans être systématiquement dominant ni écarté. Ce profil confirme la place centrale du coût dans la dynamique des compromis générés.

Ces résultats confirment que le front obtenu en phase *Growing* repose sur une combinaison de configurations modérées, dans lesquelles les compromis multiobjectif sont atteints sans recours à des extrêmes.

Résultats sur la phase Finishing

L'analyse des pondérations appliquée à la phase *Finishing* s'appuie sur les 663 solutions non dominées extraites parmi les 3003 itérations réalisées avec $N = 8$. Le tableau 6.2 présente la distribution des pondérations retenues sur chacun des objectifs, regroupées selon les niveaux discrets $\lambda_i \in \{0, \frac{1}{8}, \ldots, 1\}$.

Table 6.2 – Distribution des pondérations retenues sur la phase Finishing, selon la règle de sélection (first ou last)

λ_i	Coût	CC	Conso P	ENTOT	Occup Sols	Eutrophisation	Acidification
Sélection ***first***							
0.000	36.45	48.95	49.25	53.16	43.83	45.03	38.86
0.125	24.70	22.59	28.77	25.60	25.90	25.90	22.74
0.250	14.61	11.75	16.27	11.30	13.55	15.51	15.36
0.375	11.30	8.89	4.22	4.82	7.38	7.38	10.39
0.500	6.33	4.67	0.75	2.26	4.97	3.46	5.87
0.625	4.22	1.66	0.75	1.96	2.71	1.36	3.77
0.750	1.66	1.05	0.00	0.60	1.20	1.05	2.26
0.875	0.60	0.30	0.00	0.30	0.30	0.30	0.60
1.000	0.15	0.15	0.00	0.00	0.15	0.00	0.15
Sélection ***last***							
0.000	36.45	48.19	49.25	53.01	45.33	45.03	38.70
0.125	24.70	22.59	28.77	26.20	24.70	25.90	22.74
0.250	14.61	12.20	16.27	11.75	13.25	15.36	15.36
0.375	11.30	9.04	4.22	4.22	7.38	7.53	10.24
0.500	6.33	4.82	0.60	1.96	4.97	3.46	6.17
0.625	4.22	1.66	0.90	1.96	2.71	1.36	3.61
0.750	1.66	1.05	0.00	0.90	1.20	0.90	2.26
0.875	0.60	0.30	0.00	0.00	0.30	0.30	0.75
1.000	0.15	0.15	0.00	0.00	0.15	0.15	0.15

La distribution observée confirme les tendances identifiées en phase *Growing*, avec une forte concentration des pondérations sur les faibles valeurs. Les pondérations nulles ($\lambda_i = 0$) sont particulièrement fréquentes sur les objectifs environnementaux, notamment ENTOT (53%), eutrophisation (45%) et CC (48–49%). Cela traduit un usage important de pondérations sélectives, dans lesquelles certains objectifs sont temporairement désactivés.

Les pondérations maximales ($\lambda_i = 1$) restent négligeables, quelle que soit la règle de sélection. Cela confirme que les solutions monoobjectif ne sont pas nécessaires pour explorer les extrémités du front.

L'objectif économique (Coût) présente une répartition plus étalée que les autres critères, avec 36.45% de pondérations nulles et une part non négligeable de pondérations intermédiaires jusqu'à $\lambda_i = 0.625$. Il est donc largement impliqué dans les compromis construits, sans être exclusif.

La comparaison entre les deux sélections montre des écarts marginaux. La version *last* fait apparaître de légères hausses sur les pondérations intermédiaires (notamment $\lambda_i = 0.250$ et 0.375) pour certains objectifs, mais sans modifier la structure globale de la répartition.

Comparée à la phase *Growing*, la distribution est ici encore plus resserrée. Au-delà de $\lambda_i = 0.5$, les fréquences deviennent marginales pour la quasi-totalité des objectifs. Ce resserrement reflète l'effet contraignant du contexte de formulation : la phase *Finishing* mobilise des compromis plus rigides, liés aux contraintes nutritionnelles et techniques supplémentaires. Le front qui en résulte est donc plus dense, mais aussi plus structuré.

Synthèse des observations

L'analyse conjointe des phases *Growing* et *Finishing* met en évidence des dynamiques de pondérations globalement similaires, tout en révélant un resserrement progressif de la structure des compromis au fil des phases de formulation.

Dans les deux cas, les solutions Pareto sont majoritairement issues de configurations où certains objectifs sont temporairement désactivés, comme l'atteste la forte prévalence des pondérations nulles. La méthode pondérée permet ainsi d'explorer efficacement la diversité des compromis sans qu'il soit nécessaire de mobiliser des pondérations maximales. Les solutions extrêmes strictement monoobjectif n'apportent ici aucun bénéfice complémentaire en termes d'exploration du front.

La phase *Finishing* se distingue toutefois par une concentration encore plus marquée des pondérations sur les faibles niveaux de λ_i, traduisant une rigidité accrue des compromis atteignables. Ce phénomène reflète l'intensification des contraintes nutritionnelles à mesure que l'on progresse dans le cycle de formulation et réduisant ainsi mécaniquement l'espace des compromis admissibles.

La comparaison entre les règles *first* et *last* révèle une stabilité globale des répartitions, avec quelques ajustements localisés en faveur de pondérations plus modérées en *last*. Ces écarts restent marginaux.

Conclusion

Ce chapitre a examiné l'impact du maillage du simplexe sur la couverture du front de Pareto obtenu par la méthode *SP2*, ainsi que la structure effective des vecteurs de pondérations contributifs. L'analyse a montré que l'enrichissement progressif du simplexe conduit à un effet de saturation : au-delà d'un certain seuil de granularité (ici $N = 8$), les gains en diversité deviennent marginaux, tandis que le coût computationnel croît de façon pseudo exponentielle.

L'étude de la répartition des pondérations met en évidence une prédominance des pondérations nulles ou faibles sur la majorité des objectifs, en particulier environnementaux. Les pondérations maximales sont quasiment absentes, et les combinaisons équilibrées sont peu contributives.

Ces observations confirment la capacité de la méthode *SP2* à générer des fronts de Pareto représentatifs et diversifiés, même sous des structures de compromis fortement contraintes.

7 Conclusion

Ce travail a permis de mettre en œuvre et d'évaluer différentes méthodes d'optimisation multicritère appliquées à la formulation d'aliments pour porcs. L'objectif était de concilier performance économique et soutenabilité environnementale, dans un contexte de filière en transition. Quatre approches ont été étudiées : deux formulations bi-objectives (Garcia et Crolard), et deux formulations multiobjectives complètes (SP1 et SP2). Chaque méthode a été testée avec une stratégie de normalisation propre, afin de garantir une comparabilité équitable entre les objectifs.

L'analyse comparative de ces approches a mis en évidence l'impact des choix méthodologiques sur la forme, la diversité et la qualité des fronts de Pareto obtenus. Les métriques mobilisées (énergie de Riesz, couverture directionnelle, dispersion et densité) ont permis une évaluation rigoureuse des fronts. Par la suite, notre étude a notamment révélé que certaines combinaisons de pondérations produisent des solutions faiblement Pareto optimales.

Ces analyses ont justifier le choix des méthodes et des normalisations retenues pour la construction d'un outil de formulation opérationnel. Cet outil vise d'abord les acteurs de la filière, en proposant, en complément de l'aliment à moindre coût, des formulations alternatives à plus faible impact environnemental. Il a également été conçu pour un usage interne, en tant qu'outil d'exploration de scénarios. L'utilisateur peut ainsi tester différentes hypothèses économiques, comme la variation des indices de prix des matières premières. Il peut également simuler des scénarios environnementaux, en modifiant la base d'ingrédients disponibles pour inclure des matières premières plus ou moins durables. Enfin, l'outil est conçu pour être transposable à d'autres phases de l'alimentation porcine, au-delà des phases de croissance et de finition.

Cette deuxième utilisation servira de base à la rédaction d'un article pour la Journée de la Recherche Porcine (JRP) de 2027. Un support de type "poster scientifique", rédigé en recto-verso, a d'ores et déjà été conçu. Il vise à présenter de manière synthétique les méthodes employées, les choix de normalisation, ainsi que les paramètres explorés (notamment la granularité de la discrétisation du simplexe).

Ces travaux ouvrent par ailleurs des perspectives méthodologiques. Une réduction ciblée de l'espace des pondérations explorées apparaît envisageable. En excluant les configurations trop extrêmes ou trop uniformes, il serait possible de diminuer significativement le nombre d'itérations, tout en conservant un front de qualité équivalente. Ce type de stratégie pourrait reposer sur un échantillonnage adaptatif, une exploration guidée par des métriques, ou encore sur des approches bayésiennes de sélection des poids.

8 Annexe

Période	Travaux réalisés
15/04/2024 – 10/05/2024	**Découverte du sujet et prise de contact** Première immersion dans l'environnement professionnel. Rencontre avec l'équipe encadrante et compréhension des objectifs du stage. Familiarisation avec les attentes et le cadre technique.
03/06/2024 – 26/07/2024	**Étude bibliographique** Lecture approfondie d'articles scientifiques sur les problèmes d'optimisation multiobjectif. Revue des principales approches en résolution biobjectif.
29/07/2024 – 06/09/2024	**Auto-formation sur les problèmes multiobjectif** Formation autonome sur la formalisation des problèmes multiobjectif. Étude des algorithmes classiques. Consolidation des bases méthodologiques.
28/10/2024 – 08/11/2024	**Implémentation de méthodes biobjectif** Développement initial de solutions biobjectif. Mise en œuvre d'algorithmes simples pour valider les choix de modélisation. Premiers tests sur des jeux de données réduits.
23/12/2024 – 10/01/2025	**Implémentation de NSGA-II et NSGA-III** Intégration et adaptation de ces deux algorithmes évolutifs multiobjectif. Difficultés rencontrées : paramétrage des opérateurs de croisement et mutation, temps de convergence.
24/02/2025 – 21/03/2025	**Implémentation avancée de méthodes multiobjectif** Extension du code aux cas plus généraux. Ajout de visualisations des fronts de Pareto. Réflexion sur la robustesse des algorithmes.
24/03/2025 – 16/05/2025	**Développement de l'outil interactif** Déploiement de l'interface utilisateur via Streamlit. Intégration des méthodes implémentées dans une interface accessible. Tests utilisateurs internes et ajustements.
19/05/2025 – 22/07/2025	**Finalisation et valorisation des travaux** Rédaction du rapport d'alternance et conception du poster. Réception de retours critiques de l'équipe, corrections et mises à jour de l'outil. Réflexion sur les améliorations possibles.

Bibliographie

Agreste (oct. 2024). *Porcins - En 2023, une production en baisse et des prix élevés*. Synthèses conjoncturelles 430. Ministère de l'Agriculture et de la Souveraineté alimentaire. URL : https://agreste.agriculture.gouv.fr/agreste-web/download/publication/publie/SynAbo23430/consyn430202410-Porcins.pdf.

Audet, Charles et al. (2021). « Performance indicators in multiobjective optimization ». In : *European Journal of Operational Research* 292.2, p. 397-422.

Blot, Aymeric, Marie-Éléonore Kessaci et Laetitia Jourdan (2018). « Survey and unification of local search techniques in metaheuristics for multi-objective combinatorial optimisation ». In : *Journal of Heuristics* 24.6, p. 853-877. URL : https://doi.org/10.1007/s10732-018-9381-1.

Coello Coello, Carlos A. et María S. Lechuga (2002). « MOPSO : A Proposal for Multiple Objective Particle Swarm Optimization ». In : *Proceedings of the 2002 Congress on Evolutionary Computation*, p. 1051-1056.

Crolard, Cécile (2018). *Optimisation multicritère de la formulation des aliments : application à l'alimentation porcine et aquacole*. Rapport de stage de fin d'études, encadré par Florence Garcia-Launay et Sylvain Dauguet.

Das, Indraneel et J. Dennis (1997). « A closer look at drawbacks of minimizing weighted sums of objectives for Pareto set generation in multicriteria optimization problems ». In : *Structural Optimization* 14, p. 63-69.

Deb, Kalyanmoy et al. (2002). « A fast and elitist multiobjective genetic algorithm : NSGA-II ». In : *IEEE transactions on evolutionary computation* 6.2, p. 182-197.

Ehrgott, Matthias (2005). *Multicriteria Optimization*. 2nd. Springer Series in Operations Research and Financial Engineering. Berlin, Heidelberg : Springer. ISBN : 978-3-540-21398-7.

Espagnol, Sandrine et al. (2016). *ECOALIM : Améliorer les bilans environnementaux des élevages en optimisant leurs ressources alimentaires*. Rapport final 1260C0061. Programme REACCTIF, ADEME. URL : https://ecoalim.ademe.fr.

FranceAgriMer (juillet 2023). *La consommation de viandes en France en 2022*. Rapp. tech. 412. Consulté le 9 avril 2025. FranceAgriMer. URL : https://www.franceagrimer.fr/fam/content/download/71709/document/SYN-VIA-Conso%20viande%20Fce2022.pdf?version=2.

Garcia-Launay, Florence et al. (2018a). « Multiobjective formulation is an effective method to reduce environmental impacts of livestock feeds ». In : *British Journal of Nutrition*, p. 1-12. DOI : 10.1017/S0007114518002672. URL : https://doi.org/10.1017/S0007114518002672.

— (2018b). « Multiobjective formulation is an effective method to reduce environmental impacts of livestock feeds ». In : *British Journal of Nutrition*. Accessed : 2024-05-17, p. 1-12. URL : https://doi.org/10.1017/S0007114518002672.

Hardin, Douglas P et Edward B Saff (2002). « Discrepancy and energy of point distributions on the sphere ». In : *Bulletin of the American Mathematical Society* 39.4, p. 439-477.

INRAE (2021). *Alimentation des porcs et impacts environnementaux*. Rapp. tech. URL : https://hal.inrae.fr/hal-03286725/file/ASIRPA-alimentation%20porcs-25p-FR-2021.pdf.

Jozefowiez, Nicolas (2013a). « Optimisation combinatoire multi-objectif : des méthodes aux problèmes, de la Terre à (presque) la Lune ». HDR soutenue le 03 décembre 2013. Habilitation à diriger des recherches. Toulouse, France : Institut National Polytechnique de Toulouse. URL : https://theses.hal.science/tel-01104895.

— (2013b). « Optimisation combinatoire multi-objectif : des méthodes aux problèmes, de la Terre à (presque) la Lune ». HAL Id : tel-01104895, Submitted on 19 Jan 2015. Thèse de doct. Institut

National Polytechnique de Toulouse (INP Toulouse). URL : https://theses.hal.science/tel-01104895.

Knowles, Joshua D. et David W. Corne (1999). « The Pareto Archived Evolution Strategy : A New Baseline Algorithm for Multiobjective Optimization ». In : *Proceedings of the 1999 Congress on Evolutionary Computation-CEC99 (Cat. No. 99TH8406)*. T. 1. IEEE, p. 98-105.

La Coopération Agricole (mars 2025). *Crise internationale : La Coopération Agricole mobilisée pour la souveraineté alimentaire*. https://www.lacooperationagricole.coop. Communiqué de presse.

Li, Hui, Shengxiang Yang et Xiaohui Liu (2015). « Performance Comparison Indicator : A New Approach for Comparing Pareto Fronts ». In : *Information Sciences* 293, p. 94-114.

Miettinen, Kaisa (1999). *Nonlinear multiobjective optimization*. Springer Science & Business Media.

Ministère de l'Agriculture et de la Souveraineté Alimentaire (2022). *Évolution du climat et ses effets sur l'agriculture, émissions de GES du secteur et stockage carbone*. Accessed : 2024-05-17. URL : /mnt/data/2212_4_EvolutionClimat_FIC.pdf.

Statista (2023). *Critères des Français lors de l'achat de viande 2023*. Consulté le 9 avril 2025. URL : https://fr.statista.com/statistiques/1440966/criteres-achat-viande/.

Venkat, Vandana, Sheldon H Jacobson et James A Stori (2004). « A post-optimality analysis algorithm for multi-objective optimization ». In : *Computational Optimization and Applications* 28.3, p. 357-372.

Wilfart, Aurélie, Léonie Dusart et al. (2018). « Réduire les impacts environnementaux des aliments pour les animaux d'élevage ». In : *INRA Productions Animales* 31.3, p. 289-306. DOI : 10.20870/productions-animales.2018.31.2.2285. URL : https://doi.org/10.20870/productions-animales.2018.31.2.2285.

Wilfart, Aurélie, Sandrine Espagnol et al. (2016). « ECOALIM : A Dataset of Environmental Impacts of Feed Ingredients Used in French Animal Production ». In : *PLOS ONE* 11.12, e0167343. DOI : 10.1371/journal.pone.0167343. URL : https://doi.org/10.1371/journal.pone.0167343.

Wilfart, Aurélie, Aurélie Tailleur et al. (2017). *ECOALIM : Prolongements méthodologiques concernant la réalisation d'ACV d'intrants alimentaires du bétail*. Rapport technique. Livrable complémentaire du projet ECOALIM, coordonné par Sandrine Espagnol. France : Projet ECOALIM, ADEME.

Zhang, Qingfu et Hui Li (2007). « MOEA/D : A Multiobjective Evolutionary Algorithm Based on Decomposition ». In : *IEEE Transactions on Evolutionary Computation*. T. 11. 6. IEEE, p. 712-731.

Zitzler, Eckart et Sébastien Künzli (2004a). « Indicator-Based Selection in Multiobjective Search ». In : *International Conference on Parallel Problem Solving from Nature*. Springer, p. 832-842.

— (2004b). « Indicator-Based Selection in Multiobjective Search ». In : *International Conference on Parallel Problem Solving from Nature*. Springer, p. 832-842.

Zitzler, Eckart, Marco Laumanns et Lothar Thiele (2001). « SPEA2 : Improving the Strength Pareto Evolutionary Algorithm ». In : *EUROGEN*, p. 95-100.